

学校代码： 10246

学 号： 23210720201

復旦大學

硕 士 学 位 论 文
(专业学位)

面向语音与多模态伪造检测的安全评估方法与防护
系统研究

Research on Security Evaluation Methods and Defense Systems for
Speech and Multimodal Forgery Detection

院 系： 未来信息创新学院

专业学位类别（领域）： 电子信息

完 成 日 期： 2026 年 3 月 1 日

目录

摘要	I
Abstract	II
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	4
1.3 论文主要工作与贡献	7
1.4 论文组织结构	8
第二章 相关理论与技术基础	10
2.1 深度学习与特征表示	10
2.2 语音信号处理与声纹识别	14
2.3 伪造生成与检测原理	17
第三章 面向语音匿名化系统的安全评测方法研究	20
3.1 引言	20
3.2 SpecWav-Attack 模型架构	20
3.3 实验设置与结果分析	25
3.4 本章小结	27
第四章 基于动态特征选择机制的视频伪造检测方法	28
4.1 引言	28
4.2 SFE-Net 模型架构	28
4.3 实验设置与结果分析	34
4.4 本章小结	38
第五章 基于多模态大模型的音视频联合伪造检测方法	39
5.1 引言	39

5.2 AV-LMMDetect 模型架构	39
5.3 实验设置与结果分析	44
5.4 本章小结	51
第六章 面向语音安全的双因素级联验证系统设计与实现	52
6.1 引言	52
6.2 ASV+ADD 级联系统架构	52
6.3 硬件实现与集成方案	55
6.4 应用场景	57
6.5 本章小结	58
第七章 总结与展望	59
7.1 全文工作总结	59
7.2 研究局限性分析	60
7.3 未来研究方向	61
参考文献	63
攻读学位期间研究成果	69

摘要

随着深度伪造技术在语音、视频及音视频同步伪造等领域的快速发展，多媒体内容安全与语音隐私保护面临严峻挑战。语音匿名化的保护效果与安全边界尚缺乏系统评估，视频伪造检测在跨场景、跨数据集及未知伪造类型下泛化能力不足，音视频联合伪造检测也面临跨模态对齐与时序建模困难等问题。针对上述挑战，本文围绕语音与多模态伪造检测的安全评估方法与防护系统展开研究，重点开展了隐私风险评估、单模态伪造检测、多模态联合检测及系统实现等方面的工作。论文的主要工作和成果可归纳如下：

1. 针对语音匿名化场景下残余身份信息难以检测与量化评估的问题，提出了基于频谱增强与自监督表示学习的匿名语音隐私风险分析方法。该方法能够识别并量化匿名语音中仍然保留的说话人相关信息，用于评估匿名化系统对身份特征的抑制效果，并为语音隐私保护能力分析提供依据。

2. 针对视频伪造检测依赖固定特征、对未知伪造类型和跨数据集场景泛化能力不足的问题，设计了生物启发式动态特征选择的视频伪造检测网络。该方法通过融合多类互补特征并引入动态筛选机制，增强了模型对关键伪造线索的表征能力，提高了复杂场景下的鲁棒性与泛化能力。

3. 针对音视频联合伪造检测中跨模态信息对齐困难、异常模式建模不足的问题，构建了基于多模态大模型的统一伪造检测框架。该框架实现了音频与视觉信息的联合建模与协同判别，能够更有效地捕获跨模态异常线索，提升多模态伪造检测的准确性与适应能力。

4. 针对语音安全防护方法缺乏实际部署载体的问题，设计并实现了集说话人认证与音频伪造检测于一体的级联式语音安全装置。该系统可对输入语音进行身份合法性验证与伪造内容检测，实现双重安全验证，为语音安全防护技术的工程应用提供参考。

关键词: 深度伪造; 语音隐私; 视频伪造检测; 多模态大模型; 音视频安全

中图分类号: TP391.41

Abstract

With the rapid development of deepfake technologies in speech synthesis, speaker cloning, video generation, and audio-visual synchronized forgery, multimedia content security and speech privacy protection are facing serious challenges. The effectiveness and security boundaries of speech anonymization still lack systematic evaluation. Meanwhile, video forgery detection suffers from insufficient generalization across scenes, datasets, and unseen forgery types, and audio-visual forgery detection also faces difficulties in cross-modal alignment and temporal modeling. To address these challenges, this thesis studies security evaluation methods and protection systems for speech and multimodal forgery detection, with a focus on privacy risk assessment, unimodal forgery detection, multimodal joint detection, and system implementation. The main contributions of this thesis are summarized as follows.

1. To address the difficulty of detecting and quantitatively evaluating residual identity information in speech anonymization scenarios, a privacy risk analysis method for anonymized speech based on spectral enhancement and self-supervised representation learning is proposed. This method can identify and quantify speaker-related information that still remains in anonymized speech, thereby evaluating the suppression effect of anonymization systems on identity features and providing support for speech privacy protection assessment.

2. To address the limitations of video forgery detection methods that rely on fixed features and generalize poorly to unseen forgery types and cross-dataset scenarios, a biologically inspired dynamic feature selection network for video forgery detection is designed. By integrating multiple complementary features and introducing a dynamic selection mechanism, the proposed method enhances the representation of critical forgery cues and improves robustness and generalization in complex scenarios.

3. To address the difficulties of cross-modal alignment and insufficient anomaly modeling in audio-visual joint forgery detection, a unified forgery detection framework based on a multimodal large model is constructed. This framework performs joint modeling and collaborative discrimination of audio and visual information, enabling more effective capture of cross-modal anomalous cues and improving the accuracy and adaptability of multimodal forgery detection.

4. To address the lack of practical deployment carriers for speech security protection methods, a cascaded speech security device integrating speaker authentication and audio forgery detection is designed and implemented. The system performs both identity legitimacy verification and forged-

content detection on input speech, achieving dual security verification and providing a reference for the engineering application of speech security protection technologies.

Keywords: deepfake; speech privacy; video forgery detection; large multimodal models; audio-visual security

CLC Number: TP391.41

第一章 绪论

1.1 研究背景与意义

1.1.1 深度伪造技术的发展与威胁

近年来，随着深度学习技术的持续突破，生成模型在图像、语音与视频合成领域取得显著进展。生成对抗网络（Generative Adversarial Networks, GAN）[1]、变分自编码器（VAE）[2] 以及扩散模型（Diffusion Models）[3] 等生成框架的提出，使高质量内容生成成为可能。在此基础上，深度伪造（Deepfake）技术逐渐形成并快速发展，其核心在于利用深度神经网络对目标对象的外观或声音特征进行建模与替换，从而生成高度逼真的伪造内容。如图 1-1 所示，深度伪造技术已经广泛应用于人脸替换、身份仿冒、内容生成与交互认证等场景，这在提升内容生成能力的同时，也带来了身份欺骗、隐私泄露和信息安全等风险。



图 1-1 深度伪造图片使用场景示意

在语音领域，基于神经网络的端到端语音合成（Text-to-Speech, TTS）与语音转换（Voice Conversion）技术不断成熟。WaveNet[4]、Tacotron[5] 等模型的出现推动了自然语音生成质量的飞跃，而后续基于自监督学习的语音表示模型（如 wav2vec 2.0[6]）进一步提升了声学特征建模能力。近年来，语音克隆（Voice Cloning）技术实现了“少样本克隆”，攻击者仅需数秒目标语音样本即可重建说话人音色特征，从而生成与目标声音高度相似的伪造语音。此类技术已被用于电话诈骗、企业资金转账欺诈及身份冒充等场景，对金融安全与社会信任体系造成严重冲击。

相比图像或视频伪造，语音伪造具有更强的实时性与隐蔽性。语音交互场景（电话会议、语音消息、智能助手）通常缺乏视觉辅助验证，使得伪造语音更易被接受。攻击者可以

在低成本条件下实施高收益诈骗，显著提高攻击成功率。

在视觉领域，基于 GAN 的人脸替换（FaceSwap）[7] 与面部重演（Face2Face）[8] 技术能够精准操控人脸表情与身份信息。扩散模型的引入进一步提升了图像与视频生成质量，使伪造视频在空间细节与时间连续性方面接近真实内容如图 1-2 所示。深度伪造视频已被用于制造虚假新闻、政治操纵、公众人物诽谤及恶意传播等行为，对社会舆论与国家安全构成潜在威胁。



图 1-2 名人换脸照片

更为复杂的是，音视频联合伪造技术的兴起使攻击方式进一步升级。跨模态生成模型能够同时操控语音与面部表情，实现音唇同步与语义一致的高保真伪造效果。这种跨模态一致性显著提升了伪造内容的可信度，使传统单模态检测方法面临挑战。因此，构建面向语音、视频及音视频多模态场景的统一防御体系具有重要现实意义。

1.1.2 语音、视频与音视频伪造检测面临的挑战

尽管深度伪造检测技术已成为研究热点，但在不同模态下仍面临诸多不同的关键挑战。

(1) 语音伪造检测的挑战

当前音频深度伪造检测（Audio Deepfake Detection, ADD）方法通常基于频谱特征、相位特征或深度神经网络模型进行判别。然而，随着扩散式语音生成模型与大规模预训练模型的引入，伪造语音在频谱平滑性与高频细节方面表现更为自然，使传统基于显式伪影的检测方法逐渐失效。

此外，语音检测模型普遍存在泛化能力不足问题。当测试数据分布与训练数据存在差异（跨语言、跨设备、跨噪声环境）时，检测性能显著下降。同时，攻击者可通过对抗训练或自适应攻击策略针对检测模型进行优化，进一步削弱系统鲁棒性。现实环境中的信号压缩、

传输失真与背景噪声也增加了检测难度。

(2) 视频伪造检测的挑战

视频深度伪造检测方法多基于空间异常特征、频域分析或时序一致性建模。然而，随着生成模型对高频细节与时间一致性的精细建模能力增强，伪造视频中的明显伪影逐渐减少。传统基于局部异常区域检测的方法难以应对高质量生成内容。

视频数据具有时序结构复杂、计算成本高等特点，实时检测面临资源瓶颈。此外，社交媒体平台的多次压缩与再编码会破坏原始伪造痕迹，降低检测模型性能。因此，提升视频检测方法的鲁棒性与可扩展性仍是重要挑战。

(3) 音视频联合伪造检测的挑战

在音视频联合场景中，攻击者通过跨模态生成模型实现音唇同步与语义匹配，使单模态检测方法难以发现异常。音频与视频之间存在复杂的时序关联与语义耦合关系，如何有效建模跨模态一致性成为关键问题。

当前多数方法采用简单特征拼接或浅层融合策略，难以捕捉深层语义关联与时间同步关系。随着多模态生成模型能力增强，伪造内容在跨模态层面的自然度不断提升，检测难度进一步加大。

1.1.3 多模态与大模型驱动的安全防御趋势

针对上述挑战，研究方向逐步从单模态检测向多模态融合与大模型驱动的统一建模框架演进。

多模态检测方法通过联合建模音频与视频信息，从音唇同步一致性、语义匹配及情感表达协调等多个维度进行综合判别。相比单模态方法，多模态融合能够利用模态间互补信息，提高检测的鲁棒性与泛化能力。

近年来，大型多模态模型（Large Multimodal Models, LMMs）在跨模态表示学习与推理方面展现出强大能力。基于大规模预训练与指令微调策略，多模态模型能够在统一框架下理解语音、视觉与文本信息，进行更高层次的语义一致性分析。从技术演进角度看，如图 1-3 所示，多模态大模型自 2022 年以来在模型规模、任务覆盖范围和跨模态协同能力方面均实现了快速发展，逐渐由早期的视觉问答与图文理解扩展到复杂推理、视频理解及通用智能体等更高层次任务。这种“生成-理解一体化”的建模范式为深度伪造检测提供了新的技术路径。

因此，从语音鉴伪、视频鉴伪到音视频联合检测，再进一步向多模态与大模型驱动的全模态安全框架拓展，已成为深度伪造防御领域的重要发展方向。围绕这一演进路径开展系统

SpecAugment、Spectrogram Resizing 等方法通过在频域或时间域对训练数据进行多样化扰动,使攻击模型对不同语音条件具备更强适应能力,从而提升对匿名语音的识别成功率。整体来看,语音匿名化与攻击技术之间呈现出持续演化的对抗态势,单一防护策略难以构建长期稳固的安全体系。

1.2.2 视频深度伪造检测方法

视频深度伪造检测是计算机视觉与数字取证领域的研究热点。随着 FaceSwap[7]、DeepFakes[12]、Face2Face[8] 和 NeuralTextures [13] 等生成方法不断演进,伪造视频在空间细节与时间一致性方面逐步接近真实视频。不同伪造技术在生成机制上存在差异,因此产生的伪造特征分布亦有所不同。例如,FaceSwap 往往在融合边界处留下混合痕迹与光照不一致现象;DeepFakes 在频域中可能呈现特定高频模式;Face2Face 在表情迁移过程中可能引入几何不自然变形;NeuralTextures 则可能在纹理分布与细节一致性方面出现异常。

在检测方法方面,研究大体可分为空间域方法与频率域方法。空间域方法直接在像素空间提取伪造线索。CapsuleNet[14] 利用胶囊网络捕捉面部局部到整体的层次结构特征,对融合边界区域较为敏感;Face X-ray [15] 通过分析融合区域的混合频率信号实现判别;CORE [16] 方法关注面部几何一致性,检测不合理的空间变换。这类方法在针对特定伪造类型时表现较好,但当生成模型不断优化边界与光照细节时,其效果受到限制。

频率域方法则从傅里叶频谱或相位信息角度分析生成过程遗留的特征。F3Net [17]通过频率感知分解网络提取高频伪造线索;SPSL [18] [17] 结合空间与相位浅层特征进行联合判别。研究表明,深度伪造生成中的上采样与插值操作会在频域中留下特定模式,频率分析能够捕捉这些“指纹”。

随着深度神经网络的广泛应用,基于端到端学习的检测方法逐渐成为主流。Xception[19] 网络因其深度可分离卷积结构,在 FaceForensics++[20] 数据集上取得优异表现,成为视频伪造检测的基准模型之一。随后,EfficientNetB4[21] 等高效网络结构通过复合缩放策略在性能与参数效率之间取得良好平衡,被广泛应用于伪造检测任务。

尽管上述方法在已知数据集上取得较高准确率,但普遍存在泛化能力不足的问题。当训练集与测试集伪造类型不一致时,检测性能显著下降。部分研究尝试通过元学习、域适应等方法增强跨域性能,但多数方法仍采用静态特征表达机制,缺乏根据输入动态调整特征优先级的能力,限制了在复杂场景下的表现。

1.2.3 音视频多模态检测技术

随着音视频联合伪造技术的发展,单模态检测方法逐渐难以应对跨模态一致的高质量伪

造内容。多模态检测技术通过融合音频与视频信息，挖掘跨模态关联特征和不一致线索，相比单模态方法具有更强的判别能力。

早期多模态方法主要采用特征级融合策略。LipForensics [22] 通过分析唇部运动与语音节奏之间的同步关系识别伪造；Multiple-Attention[23] 方法利用注意力机制对音视频特征进行自适应加权融合。这类方法在音唇不同步场景下有效，但对高质量同步伪造的鲁棒性有限。

近年来，深度多模态融合方法逐渐成为主流。AVFF[23] [24] 提出联合建模音频与视频时空特征的融合框架；MRDF [25] 采用多分辨率特征融合策略，在不同尺度上捕捉伪造线索；TALL[26] 则基于 Transformer 架构构建跨模态注意力机制，实现更深层次的模态交互。这类方法增强了音视频之间的语义关联建模能力。

大型多模态模型的出现为伪造检测带来新的技术机遇。CLIP[27]、BLIP [28] 等视觉-语言模型展现出强大的跨模态理解能力；Qwen 3 Omni[29]、GPT-4 [30] 等多模态大模型能够同时处理视觉、语音与文本信息，在统一表示空间中进行语义推理。以 Qwen3-Omni 为例，如图 1-4 所示，该模型在复杂推理、多语言理解、长语音处理和实时交互等方面表现出较强能力，体现了当前多模态大模型在跨模态信息建模与统一理解方面的发展趋势。然而，大模型通常在自然数据上预训练，对细粒度伪造特征的敏感度有限。因此，如何通过监督微调与任务适配提升其对伪造线索的判别能力，成为当前研究重点。




图 1-4 Qwen3 omni

FakeAVCeleb[31] 与 MAVOS-DD[32] 等多模态深度伪造数据集的发布，为算法评估提供了统一平台，推动多模态检测技术向更强泛化能力与跨语言鲁棒性方向发展。

1.2.4 语音安全硬件防护研究

语音安全研究长期集中于算法层面，包括匿名化处理、语音加密与伪造检测模型。然

而，在实际应用环境中，纯软件方案存在被绕过或篡改的风险，且语音数据在采集与传输过程中可能遭受截获。

硬件级安全防护逐渐成为重要方向。现有研究包括基于可信执行环境（TEE）的语音处理方案，通过硬件隔离保护敏感数据；端侧语音处理芯片，在设备本地完成特征提取与模型推理；语音加密硬件模块，在采集阶段即进行加密处理。

在功能层面，说话人认证（ASV）技术广泛应用于身份验证场景，ECAPA-TDNN[33]、Res2Net[34] 等模型在声纹识别任务上取得优异性能。然而，ASV 仅解决“是谁在说”的问题，无法判断语音是否为伪造。音频深度伪造检测（ADD）技术则专注于识别语音合成或声音转换，但不验证身份。

目前尚缺乏将 ASV 与 ADD 有机结合的商用系统。构建双因素语音安全验证机制，将身份验证与真伪判别级联集成，并封装为硬件装置嵌入智能语音终端或支付设备中，可在语音采集前端完成联合决策，从而显著提升系统整体安全性与可靠性。

1.3 论文主要工作与贡献

本文围绕语音隐私安全与多模态内容伪造监测展开系统研究，构建了从音频安全评测、单模态视频检测到音视频联合建模与系统级防护的完整技术体系，形成了一条由单模态到多模态、由算法模型到工程实现逐级递进的研究路线。主要工作与创新点如下：

1.3.1 基于频谱增强的匿名语音攻击方法研究

针对语音匿名化系统缺乏高强度安全评测机制的问题，本文提出了一种面向匿名语音身份残留检测的评估模型。该方法将自监督学习模型 Wav2Vec 2.0 与频谱调整（Spectrogram Resizing）数据增强策略相结合，通过两阶段增量训练机制，显著提升了模型对匿名语音中潜在身份特征的辨识能力。在 VoicePrivacy Challenge 数据集上的实验结果表明，该方法在等错误率（EER）指标上相比传统评测模型降低 30%以上，揭示了现有匿名化系统在深层表示空间中的身份信息残留现象。该研究从音频单模态安全监测角度出发，为语音隐私保护性能评估提供了技术支撑。（相关研究成果以第一作者发表在 ICASSP2025 上）

1.3.2 生物启发式选择性特征网络的视频伪造检测方法

面向视频深度伪造技术快速演进与跨数据泛化能力不足的问题，本文受生物学差异基因表达（Differential Gene Expression）机制启发，提出了一种动态特征选择网络 SFE-Net。该模型集成光照一致性、高频频域分析、压缩重建特征、形态学结构信息与纹理分布五类特征提取分支，并设计选择性特征激活机制，使模型能够根据不同伪造类型自适应调整特征权重。实验结果表明，SFE-Net 在 FaceSwap、DeepFakes、Face2Face、NeuralTextures 等多

种伪造场景中均取得优异性能，跨数据集测试中 AUC 达到 79.5%，显著提升了视频单模态伪造检测的泛化能力。该工作实现了从音频安全评测向视觉模态伪造监测的技术延伸。(相关研究成果以第一作者发表在 ICASSP2025 上)

1.3.3 基于多模态大模型的音视频联合伪造检测方法

针对复杂音视频联合伪造场景中跨模态不一致性难以建模的问题，本文提出一种基于大型多模态模型的统一检测框架。该方法通过两阶段监督微调（SFT）策略，将通用多模态模型 Qwen 2.5 Omni 适配至伪造检测任务，设计音视频联合编码机制与 Top-2 Token 预测策略，实现跨模态语义与时序一致性建模。在 FakeAVCeleb 数据集上，AV-LMMDetect 达到 99.2% 的 AUC 和 98.02% 的准确率；在多语言 MAVOS-DD 数据集四种开放集场景下均取得最优或次优结果，展现出良好的跨语言鲁棒性与开放域泛化能力。该研究完成了从单模态检测向多模态融合监测的关键跨越。(相关研究成果以共一作者发表在 ICASSP2026 上)

1.3.4 面向语音安全的双因素级联验证系统设计与实现

在算法层面研究基础上，本文进一步从系统工程角度出发，设计并实现了一种融合说话人认证（ASV）与音频深度伪造检测（ADD）的级联式双因素验证装置。系统采用模块化结构，将语音采集、特征提取、身份认证与真伪检测集成于物理设备中。其中 ASV 模块基于 ECAPA-TDNN 实现高精度声纹识别，ADD 模块结合频谱与相位一致性分析进行伪造检测，控制单元完成联合决策输出。该装置可部署于智能语音助手、语音支付终端、智能门锁及车载系统等场景，实现物理级安全防护。相关技术已形成发明专利申请。

综上，本文围绕语音与多模态内容安全问题，构建了一条贯穿音频安全评测、视频伪造检测、多模态融合建模与系统级实现的完整技术链条：首先，在音频模态层面评估匿名语音中的身份信息残留；其次，在视觉模态层面提升视频伪造检测的泛化能力；进一步在多模态层面建立统一的音视频联合判别框架；最终在系统工程层面实现算法与硬件协同的双因素安全验证机制。整体实现了从单模态算法创新到多模态融合建模，再到工程级安全落地的跨层级整合，为多媒体内容安全与隐私保护提供了系统化、可扩展的解决方案。(相关研究成果以第一发明人申请发明专利,并初审合格)

1.4 论文组织结构

本文共分为七章，各章内容安排如下：

第一章 绪论

介绍深度伪造技术与语音隐私保护的研究背景与现实威胁，分析语音、视频以及音视频联合伪造所面临的技术挑战，系统梳理国内外研究现状，并阐述本文的研究思路、主要工作与创

新贡献，明确全文的技术路线与组织结构。

第二章 相关理论与技术基础

系统介绍深度学习基本理论、语音信号处理与说话人表示学习方法、视频伪造生成与检测原理，以及多模态表示学习与跨模态建模技术，为后续模型设计与实验分析提供理论支撑。

第三章 面向语音匿名化系统的安全评测方法研究

本章从语音模态出发，针对现有匿名化系统在深层表示空间中安全评估不足的问题，提出一种基于频谱增强与自监督表示学习的匿名语音安全评测方法。围绕模型结构设计、两阶段训练策略与实验验证展开系统分析，重点评估匿名语音中潜在身份信息的残留情况，揭示匿名化处理在高维表示空间中的可分性特征。本章为后续多模态内容安全研究奠定音频单模态安全监测基础。

第四章 基于动态特征选择机制的视频伪造检测方法

在语音安全评测研究基础上，研究范围拓展至视觉模态，聚焦视频内容中的深度伪造检测问题。针对现有视频检测模型跨数据泛化能力不足的挑战，提出生物启发式选择性特征表达网络，通过多分支视觉特征提取结构与动态激活机制，实现对不同伪造类型的自适应特征选择与联合判别。通过跨数据集实验系统验证模型的鲁棒性与泛化能力。本章标志着研究从语音安全评测延伸至视觉内容安全监测，实现单模态从音频到视频的拓展。

第五章 基于多模态大模型的音视频联合伪造检测方法

在单模态语音与视觉研究基础上，进一步面向复杂音视频联合伪造场景，构建基于多模态大模型的统一检测框架。重点介绍跨模态联合编码机制与两阶段监督微调策略，实现音频与视觉特征在语义与时序层面的深度融合，并在多语言、多场景数据集上系统验证模型性能。该研究体现了从单模态独立检测向多模态统一建模范式的演进，实现跨模态一致性判别能力的提升。

第六章 面向语音安全的双因素级联验证系统设计与实现

在前述算法模型研究基础上，本章从系统工程层面出发，设计并实现一种融合说话人认证与音频伪造检测的级联式安全装置。围绕整体架构设计、功能模块划分与硬件实现方案展开论述，构建集语音采集、身份认证与真伪检测于一体的物理级安全防护系统。该章节展示了从算法模型创新到工程化部署的完整转化路径，实现软硬件协同的安全保障机制。

第七章 总结与展望

总结全文研究工作与主要贡献，分析当前研究的局限性，并对多模态内容安全与语音隐私保护领域的未来发展方向进行展望

第二章 相关理论与技术基础

2.1 深度学习与特征表示

2.1.1 卷积神经网络

卷积（Convolution）是卷积神经网络中最核心的运算之一，其本质是通过局部连接和权重共享机制，对输入数据进行特征提取。对于二维图像而言，卷积操作通常是指利用一个尺寸较小的卷积核（Kernel）在输入特征图上按照一定步长进行滑动，并在每一个空间位置上与对应局部区域执行加权求和运算，从而生成输出特征图。




图 2-1 卷积计算示例

如图 2-1 所示，卷积过程由输入图片、卷积核和输出特征图三部分组成。设输入特征图为 X ，卷积核为 W ，则卷积核在输入图像的局部区域上逐位置滑动，每移动到一个位置，便对当前感受区域内的像素值与卷积核参数进行逐元素乘积并求和，必要时再加上偏置项，最终得到输出特征图中对应位置的响应值。其计算过程可表示为：

$$Y(i, j) = \sum_m \sum_n X(i + m, j + n) W(m, n) + b \quad (2-1)$$

其中， $X(i + m, j + n)$ 表示输入特征图在局部区域内的像素值， $W(m, n)$ 表示卷积核对应位置的权重参数， b 为偏置项， $Y(i, j)$ 为输出特征图在位置 (i, j) 处的结果。

从空间关系上看，输出特征图中的每一个像素值都由输入图像中一个局部区域共同决定，该局部区域称为该输出位置的感受野（Receptive Field）。如图所示，当采用大小为 3×3 的卷积核进行单层卷积时，输出特征图中某一像素对应的输入感受野大小即为 3×3 。这说明卷积操作具有明显的局部感知特性，能够重点建模输入数据中的局部结构信息。

卷积操作相较于传统全连接结构具有两个显著优势。首先，卷积通过局部连接减少了网络中参数的数量，使模型更适合处理具有空间结构的数据，如图像和视频。其次，卷积通过权值共享使同一组卷积核参数可在整个输入空间内重复使用，从而提升了参数利用效率，并增强了模型对平移变化的适应能力。

在实际应用中，不同卷积核能够学习到不同类型的局部特征，例如边缘、纹理、轮廓及更高层次的语义模式。因此，卷积层的作用可以概括为：通过在输入特征图上滑动卷积核，对局部区域进行加权聚合，实现从原始数据中自动提取判别性特征，为后续的分类、检测或识别任务提供有效的表示基础。

2.1.2 注意力机制原理

注意力机制（Attention Mechanism）最初受到人类视觉选择性关注过程的启发，其核心思想是：在处理输入信息时，模型并非对所有特征赋予相同权重，而是根据当前任务目标，动态地关注与当前输出更相关的部分，从而提升特征表达能力和信息利用效率。对于序列建模、图像理解以及多模态融合等任务，注意力机制能够有效缓解长距离依赖建模困难和关键信息易被淹没的问题，因此已成为现代深度学习模型中的关键组成部分。

传统的编码方式通常将输入序列压缩为固定长度的上下文向量，这种方式在处理长序列时容易造成信息丢失。而注意力机制通过为输入中不同位置分配不同的权重，使模型能够直接从原始输入中选择性提取重要信息。其本质可以表示为：对输入特征集合中的每一个元素计算其与当前目标之间的相关性分数，再通过归一化操作得到注意力权重，最后对输入特征进行加权求和，形成更加有效的上下文表示。

一般来说，注意力机制可以表示为 Query（查询）、Key（键）和 Value（值）三组向量之间的匹配过程。设查询向量为 Q ，键向量为 K ，值向量为 V ，则注意力的计算过程可以分为以下三个步骤：

- (1) 相关性计算：计算查询向量与各键向量之间的相似度，用于衡量当前输入位置对目标位置的重要程度；
- (2) 权重归一化：通过 Softmax 函数将相似度分数归一化，得到各位置的注意力权重；
- (3) 加权求和：利用注意力权重对值向量进行加权求和，获得最终的输出表示。

其数学表达式通常写为：

$$Attention(Q, K, V) = softmax(f(Q, K))V \quad (2-2)$$

其中， $f(Q, K)$ 表示查询与键之间的匹配函数，常见形式包括点积、加性函数或缩放点积

等。在 Transformer 中，最常使用的是缩放点积注意力（Scaled Dot-Product Attention），其表达式为：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-3)$$

其中， d_k 表示键向量的维度，引入 $\sqrt{d_k}$ 的目的是防止点积结果随维度增大而过大，从而避免 Softmax 函数进入梯度过小的区域，提升训练稳定性。

从作用机理上看，注意力机制能够根据不同输入动态调整特征的重要性分布，使模型具备更强的上下文感知能力。对于序列任务，它能够捕获远距离位置之间的依赖关系；对于图像任务，它能够突出目标区域、抑制背景干扰；对于多模态任务，它还能实现不同模态间的信息对齐与交互。因此，注意力机制不仅提高了模型对关键信息的提取能力，也增强了模型的可解释性。

在实际应用中，注意力机制还进一步发展出自注意力（Self-Attention）和多头注意力（Multi-Head Attention）等形式。其中，自注意力通过在同一输入序列内部建立各元素之间的关联，使模型能够全局建模序列依赖关系；多头注意力则通过设置多个并行的注意力头，从不同表示子空间中学习特征关系，从而增强模型的表达能力。这些扩展形式推动了 Transformer 及其衍生模型在自然语言处理、计算机视觉和语音分析等领域的广泛应用。

综上所述，注意力机制通过“相关性建模—权重分配—特征聚合”的方式，实现了对输入信息的动态筛选与强化，为深度学习模型提供了更加高效、灵活的信息建模手段，也为后续 Transformer 结构和大模型的发展奠定了基础。




图 2-2 Transformer 架构图

2.1.3 自监督学习框架 Wav2Vec 2.0

Wav2Vec 2.0 是 Facebook AI Research 提出的自监督语音表示学习模型，通过在大规模无标注语音数据上进行预训练，学习到丰富的声学 and 语言特征。




图 2-3 wav2vec2 框架图

Wav2Vec 2.0 的核心思想是对比学习(Contrastive Learning)。模型首先通过卷积编码器将原始波形映射为潜在表示 z_t ，然后对部分时间步进行掩码(Masking)，通过 Transformer 网络预测被掩码位置的量化表示。训练目标是最大化正样本的相似度，同时最小化负样本的相似度：

$$L = -\log \left(\exp(\sin(c_t, q_t)/\tau) / \sum_k \exp(\sin(c_t, q_k)/\tau) \right) \quad (2-4)$$

其中 c_t 为上下文表示， q_t 为真实的量化向量， q_k 为负样本， τ 为温度参数。

经过预训练的 Wav2Vec 2.0 模型能够生成 1024 维的语音表示，这些表示不仅编码了音素、韵律等语言学信息，还隐含着说话人特征、情感特征等副语言信息。相比传统的滤波器组(Fbank)特征，Wav2Vec 2.0 特征在说话人识别、语音识别、情感识别等下游任务中表现出更强的判别能力。

在语音匿名化攻击场景中，Wav2Vec 2.0 的强大表示能力使其成为突破隐私保护的有力工具。即使语音经过音色变换、声纹转换等匿名化处理，Wav2Vec 2.0 仍能从深层特征空间中提取说话人相关的判别性信息，这为评估匿名化系统的安全性提供了重要手段。

2.1.4 大语言模型与多模态融合

大语言模型(Large Language Models, LLMs)如 GPT 系列、LLaMA[35]、Qwen 等,通过在海量文本数据上进行预训练,展现出强大的语言理解和生成能力。这些模型基于 Transformer 架构,参数量从数十亿到数千亿不等,能够进行上下文学习(In-Context Learning)、指令遵循(Instruction Following)等复杂任务。

多模态大模型(Large Multimodal Models, LMMs)在 LLMs 的基础上拓展了视觉、听觉等模态的处理能力。典型的多模态架构包括视觉编码器(如 CLIP 的视觉 Transformer)、音频编码器(如 Whisper)和语言模型主干的组合。通过模态对齐(Modality Alignment)和跨模态注意力机制,多模态模型能够理解图像、视频、音频与文本之间的复杂关联。

Qwen 2.5 Omni 是阿里巴巴提出的新一代全模态大模型,支持文本、图像、视频、音频的统一编码和推理。其架构采用了模态特定编码器+共享 Transformer 主干的设计。视觉编码器将图像/视频编码为视觉 Token 序列,音频编码器将语音编码为听觉 Token 序列,与文本 Token 共同输入到统一的 Transformer 模型中进行联合建模。

在深度伪造检测任务中,多模态大模型具有独特优势。首先,其强大的跨模态理解能力使其能够捕捉音视频的语义一致性,识别内容层面的矛盾。其次,通过监督微调(Supervised Fine-Tuning, SFT)可以将模型适配到特定检测任务,学习伪造相关的判别性特征。最后,大模型的泛化能力有助于应对未知的伪造方法和开放集场景。

然而,直接将大模型应用于伪造检测也面临挑战。大模型的预训练目标主要是语言建模和视觉-语言对齐,对细粒度的伪造痕迹(如频域异常、微表情不一致)敏感度不足。因此,需要设计有效的微调策略,如 LoRA(Low-Rank Adaptation)、提示工程(Prompt Engineering)等,在保持大模型通用能力的同时,增强其对伪造特征的识别能力。

2.2 语音信号处理与声纹识别

2.2.1 梅尔频谱与声学特征提取

语音信号处理的首要任务是从时域波形中提取有效的声学特征。梅尔频谱(Mel Spectrogram)是最常用的语音特征表示之一,其计算过程包括以下步骤:

(1) 预加重: 通过高通滤波器增强高频成分,公式为

$$y(n) = x(n) - \alpha \cdot x(n-1) \quad (2-5)$$

其中 α 通常取 0.97。

(2) 分帧与加窗: 将语音信号分割为短时帧(通常 20-40ms),对每帧应用汉明窗(Hamming

Window)以减少频谱泄漏。

(3) 短时傅里叶变换(STFT): 对每帧进行傅里叶变换,得到频域表示:

$$X(k) = \sum_{n=0}^{N-1} x(n)w(n)e^{-j2\pi k \frac{n}{N}} \quad (2-6)$$

(4) 梅尔滤波器组: 应用一组三角形滤波器,将线性频率转换为梅尔刻度。梅尔刻度更符合人耳的听觉感知特性,转换公式为:

$$Mel(f) = 2595 \cdot \log_{10}\left(1 + \frac{f}{700}\right) \quad (2-7)$$

(5) 对数能量: 对滤波器组输出取对数,模拟人耳的对数响应特性,得到最终的梅尔频谱特征。




图 2-2 梅尔频谱图

除梅尔频谱外,梅尔频率倒谱系数(MFCC)也是常用特征。MFCC 在梅尔频谱基础上进行离散余弦变换(DCT),提取更紧凑的表示。然而,在深度学习时代,梅尔频谱作为更原始的特征,能够保留更多细节信息,因此在说话人识别、语音合成等任务中被广泛采用。

2.2.2 ECAPA-TDNN 声纹识别网络

ECAPA-TDNN(Emphasized Channel Attention, Propagation and Aggregation Time Delay Neural Network)是当前最先进的说话人识别网络架构之一,其架构图如图 2-3 所示。相比传统的 x-vector 系统,ECAPA-TDNN 引入了多项创新设计。

(1) 时延神经网络(TDNN): TDNN 通过一维卷积操作捕捉语音的时序上下文信息。不同于标准卷积,TDNN 的膨胀卷积(Dilated Convolution)能够以较少的参数扩大感受野,高效

建模长距离依赖。

- (2) Res2Net 模块: 借鉴计算机视觉中的多尺度特征提取思想,Res2Net 将特征图沿通道维度分组,每组特征以不同的感受野进行处理,再进行融合。这种设计使网络能够在多个粒度上建模语音特征。
- (3) 通道注意力机制(SE-Block): Squeeze-and-Excitation 模块通过全局平均池化和两层全连接网络,学习通道间的重要性权重:

$$s = \sigma(W2\delta(W1 \cdot GAP(X))) \quad (2-8)$$

然后将权重向量 s 与特征图相乘,实现通道级别的特征重标定。

- (4) 注意力统计池化(Attentive Statistics Pooling): 不同于简单的全局平均池化,注意力统计池化学习时间步的重要性权重,分别计算加权均值和标准差,然后拼接为最终的话语级别嵌入向量。




图 2-3 ECAPA-TDNN 结构图

ECAPA-TDNN 的完整流程为: 输入梅尔频谱 $\rightarrow$ Conv1D 层 $\rightarrow$ 多个 SE-Res2Block $\rightarrow$ Conv1D 通道扩展 $\rightarrow$ 注意力统计池化 $\rightarrow$ 全连接层 $\rightarrow$ 说话人嵌入向量(通常 192 或 512 维)。该嵌入向量能够高度压缩说话人的声纹特征,用于后续的相似度匹配和身份认证。

在训练阶段,ECAPA-TDNN 通常采用 AAM-Softmax(Additive Angular Margin Softmax)损失函数,通过引入角度间隔增强类间可分性。在推理阶段,使用余弦相似度或概率线性判别分析(PLDA)计算嵌入向量间的相似度,完成说话人验证任务。

2.3 伪造生成与检测原理

2.3.1 常见深度伪造生成技术(GAN, Diffusion)

深度伪造技术的核心是生成式模型,主要包括生成对抗网络(GAN)和扩散模型(Diffusion Models)两大类。

(1) 生成对抗网络(GAN):




图 2-4 GAN 框架

GAN 由生成器 G 和判别器 D 组成,两者进行对抗训练如图 2-4 所示。生成器从随机噪声 z 生成伪造样本 $G(z)$,判别器判断输入是真实样本还是生成样本。训练目标为:

$$\min_G \max_D \left\{ (E_x [\log D(x)] + E_z [\log (1 - D(G(z)))]) \right\} \quad (2-9)$$

在人脸伪造领域，典型的生成对抗网络（GAN）方法涵盖多种技术路线。例如，FaceSwap 采用编码器-解码器架构，将源人脸的表情与姿态信息迁移到目标人脸，实现身份替换；DeepFakes 基于自编码器结构，通过共享编码器学习通用人脸表示，并利用两个独立解码器分别重建源脸与目标脸，从而完成面部融合；Face2Face 则依托表情参数驱动机制，实时捕捉源人物的面部动作并映射至目标视频，实现动态表情迁移；而 NeuralTextures 通过学习目标人物的神经纹理表示，结合几何变形与神经渲染技术，实现高质量的人脸重演。这些方法不断提升伪造效果的真实度，同时也对视频内容安全检测提出了更高挑战。

(2) 扩散模型(Diffusion Models):

扩散模型通过逐步添加噪声的正向扩散过程和去噪的反向生成过程,实现高质量样本生成如图 2-5 所示。去噪扩散概率模型(DDPM)定义了马尔可夫链:

$$x_t = 1 - \beta_t x_{t-1} + \beta_t \varepsilon, \varepsilon \sim N(0,1) \quad (2-10)$$

扩散模型在图像生成、视频合成等任务中展现出超越 GAN 的质量和多样性。




图 2-5 Diffusion 框架

在语音伪造领域，常见技术主要包括文本转语音（TTS）、语音转换（VC）以及语音克隆等方向。文本转语音技术（如 Tacotron[36]、FastSpeech[37]）能够根据输入文本直接生成自然流畅的语音；语音转换方法（如 CycleGAN-VC[38]、VQVC[39]）则通过特征映射，将源说话人的语音内容转换为目标说话人的音色与声纹特征；而语音克隆技术进一步降低了门槛，仅需数秒目标说话人的语音样本，便可重建其声音特征并合成任意文本内容的语音。这些技术的快速发展在提升语音生成质量的同时，也显著增加了语音身份伪造与滥用的安全风险。

2.3.2 基于生物特征与频率分析的检测原理

深度伪造检测的核心思想是发现生成过程中引入的伪造痕迹。这些痕迹可能源于生成算法的局限性、数据处理的不完善或物理规律的违背。主要检测原理包括：

(1) 生物一致性检测：

真实人脸视频通常遵循稳定的生理与物理规律，例如眨眼频率符合自然节律、微表情变化具有连续性、皮肤纹理分布满足真实成像特性等。而在伪造视频中，这些规律往往难以被完全准确地建模，从而暴露出可检测的异常迹象。例如，早期 DeepFakes 生成的视频中常出现眨眼行为缺失或眨眼频率异常的情况；在人脸光照建模方面，真实人脸各区域的亮度与阴影应符合统一光源约束，而伪造图像可能出现局部光照方向不一致或明暗分布矛盾；此外，在人脸融合与重建过程中还可能引入几何结构失真，使五官比例、对称性或空间布局偏离正常的解剖学约束。这些生理与物理层面的异常特征为视频伪造检测提供了重要依据。

(2) 频率域分析：

在图像伪造生成过程中，上采样与插值等操作往往会在频率域中留下可辨识的“结构指

纹”。通过傅里叶变换

$$F(u, v) = \iint \{f(x, y)e^{-j2\pi(ux+vy)}\}dxdy \quad (2-11)$$

可以将图像从空间域映射到频率域进行分析。通常情况下,真实图像的频谱分布呈现平滑的能量递减特性,符合自然图像统计规律;而伪造图像则可能在频域中表现出异常模式,例如生成网络的上采样操作引入高频周期性伪影,导致高频区域能量异常增强;相位信息由于比幅度信息更难以精确建模,真假图像在相位谱结构上往往存在明显差异;此外,部分 GAN 生成图像在特定频率位置还可能出现异常能量峰值或频谱边界结构不连续现象。这些频域特征为伪造图像的检测提供了重要的判别依据。

(3) 压缩与重建痕迹:

视频通常经过 JPEG 压缩、H.264 编码等有损压缩。真实视频在整个画面上具有一致的压缩痕迹,而伪造视频中替换的人脸区域可能经历不同的压缩历史,导致压缩伪影不一致。通过分析 DCT 系数、量化表等压缩参数,可以检测这种不一致性。

(4) 时序一致性分析:

视频是时间序列数据,相邻帧之间应保持运动连贯性和内容一致性。伪造视频可能因逐帧处理而产生时序抖动、运动不连续等问题。基于光流、时序 Transformer 等技术可以检测这类异常。

(5) 音视频同步性检测:

在音视频深度伪造中,音频和视频可能来自不同生成模型,导致口型与语音不同步、声音与表情不匹配等问题。通过建模音唇同步关系、声音与面部动作的相关性,可以识别多模态伪造。

2.4 本章小结

本章系统介绍了深度伪造检测与语音隐私保护的相关理论与技术基础。首先阐述了卷积神经网络、注意力机制、自监督学习模型 Wav2Vec 2.0、大型多模态模型等深度学习核心技术,为后续方法设计奠定理论基础。其次详细介绍了语音信号处理的基本流程,包括梅尔频谱提取和 ECAPA-TDNN 声纹识别网络的架构原理。最后从生成和检测两个角度,阐述了深度伪造技术的实现机制和检测方法的基本原理。这些理论和技术为后续章节的算法设计和系统实现提供了必要的知识储备。

第三章 面向语音匿名化系统的安全评测方法研究

3.1 引言

语音匿名化技术通过修改语音中的说话人相关特征，在尽量保留语义内容与可懂度的前提下隐藏真实身份，是当前语音隐私保护的重要技术手段。以 VoicePrivacy Challenge 为代表的国际评测推动了匿名化方法的标准化研究，主流方案通常基于声纹向量表征来伪说话人生成与神经声码器重建，实现对声纹特征的替换或扰动。

然而，现有研究多集中于语音可懂度与传统识别模型下的安全表现，对于匿名语音在深层表示空间中的身份可分性缺乏系统分析。随着表示学习技术的发展，尤其是自监督语音模型的广泛应用，匿名语音是否仍在高维特征空间中保留可区分的个体信息，成为亟需回答的重要问题。因此，有必要构建更高强度的安全评测框架，对匿名化系统在深层语音表示层面的隐私保护能力进行系统验证。

传统说话人识别方法通常基于 MFCC 等手工声学特征及 i-vector[40]、x-vector[41] 等浅层模型，对复杂匿名扰动的敏感性有限。近年来，自监督学习模型如 Wav2Vec 2.0、HuBERT 在语音表示学习方面取得显著突破，其学习到的深层特征不仅包含语音内容信息，还隐含丰富的说话人结构特征。这类模型为评估匿名语音中的潜在身份残留提供了新的技术路径。

基于此，本章提出一种面向匿名语音的安全评测方法 SpecWav-Attack，将自监督表示学习模型与频谱调整数据增强策略相结合，并通过两阶段增量训练机制构建高强度评估模型。该方法能够更加敏感地刻画匿名语音在高维表示空间中的可分性特征，从而系统分析匿名化处理对身份信息消除程度的影响。通过实验验证，本章揭示了现有匿名化系统在深层表示空间中的潜在身份信息残留现象，为后续隐私保护机制的改进提供了理论与实验依据。

3.2 SpecWav-Attack 模型架构

如图 3-1 所示，本文所采用的匿名语音攻击模型整体上由输入处理、特征提取、数据增强、说话人表征学习与分类判别五个部分组成。首先，在输入阶段，将原始语音波形及其对应的声学特征作为模型输入；随后，在特征提取阶段，利用卷积神经网络与 Transformer 结构对输入语音进行层次化建模，提取高维上下文表示。为了提升模型对匿名语音的适应能力，在训练过程中进一步引入频谱调整等数据增强策略，以模拟匿名化处理中可能产生的音色变化。之后，增强后的语音表示被送入 ECAPA-TDNN 网络，通过多尺度特征建模与注意力统计池化提取判别性说话人嵌入。最后，基于得到的说话人表示完成分类与识别，从而实

现对匿名语音中残余身份信息的有效挖掘与判别。




图 3-1 SpecWav-Attack 框架

3.2.1 基于 Wav2Vec 2.0 的深度特征提取

SpecWav-Attack 的核心在于利用 Wav2Vec 2.0 提取鲁棒的语音表示。Wav2Vec 2.0 通过在 960 小时 LibriSpeech[42] 数据集上进行自监督预训练,学习到了对语音变化鲁棒的深层特征。

在 SpecWav-Attack 中,我们使用 Wav2Vec 2.0 的 Transformer 输出作为特征。对于输入语音 y , Wav2Vec 2.0 生成序列特征 $C = [c_1, c_2, \dots, c_t]$, 每个 c_t 为 1024 维向量。这些特征不仅包含音素级别的语言学信息,还保留了说话人的声纹特征,如基频包络、共振峰分布、发音习惯等。

相比传统的 Fbank 特征, Wav2Vec 2.0 特征具有以下优势:

- (1) 鲁棒性更强: 对噪声、信道失真、音色变化等干扰具有更好的抗性。
- (2) 表示能力更强: 通过多层 Transformer 网络,学习到更抽象、更具判别性的特征。
- (3) 泛化能力更好: 大规模无监督预训练使模型能够适应多样化的语音输入。

这些特性使得 Wav2Vec 2.0 成为攻击匿名语音的有力工具,即使语音经过声纹转换、音高调整等匿名化操作, Wav2Vec 2.0 仍能从深层特征空间提取说话人相关的判别性信息。

3.2.2 频谱调整(Spectrogram Resizing)增强策略

数据增强是提升模型泛化能力的重要手段。传统的语音数据增强方法包括时间拉伸、音高变换和添加噪声等，但这些方法对匿名语音攻击任务的提升效果相对有限。为此，本文借鉴语音转换领域中的频谱调整（Spectrogram Resizing, SR）技术，设计了一种更具针对性的数据增强方案。

频谱调整的核心思想是在梅尔频谱域对频率维度进行重采样，以模拟说话人音色的多样性变化。具体而言，该增强过程主要包括以下几个步骤：首先，对原始语音进行短时傅里叶变换和梅尔滤波处理，得到对应的梅尔频谱表示；其次，在频率维度上对梅尔频谱进行垂直方向的重采样，通过插值或下采样改变其频谱结构；随后，再将调整后的频谱恢复到原始频率维度，以保证后续特征输入形式的一致性；最后，利用 Griffin-Lim 算法或神经声码器（如 HiFi-GAN）将增强后的频谱重建为时域语音信号，从而完成基于频谱结构扰动的数据生成过程。

频谱调整的本质是在频率维度引入结构性扰动，以模拟共振峰位置变化所带来的音色差异。这种变化在一定程度上接近真实说话人之间的音色差异，同时能够保持语音的语义内容基本不变。通过在增强数据上进行训练，模型能够学习到对音色变化更为鲁棒的说话人特征表示，从而提升对匿名语音的识别能力。

实验结果表明，频谱调整方法明显优于传统的数据增强策略。与时间拉伸、音高变换等方法相比，SR 更直接地模拟了匿名化过程中产生的音色扰动，因此能够有效增强模型对匿名语音的判别能力。

3.2.3 ECAPA-TDNN 说话人识别网络设计

在提取 Wav2Vec 2.0 特征后，本文采用 ECAPA-TDNN 网络进行说话人嵌入学习与分类。相较于传统的 x-vector 架构，ECAPA-TDNN 在多尺度特征建模、通道注意力机制以及时序统计聚合等方面具有更强的表征能力，因此已成为当前说话人识别任务中的主流方法之一。

ECAPA-TDNN 的输入为 Wav2Vec 2.0 输出的高维特征序列，其表示为 $C \in \mathbb{R}^{1024 \times T}$ ，其中 1024 表示特征维度， T 表示时间帧数。

首先，网络通过一层一维卷积对输入特征进行初步映射，将通道数由 1024 调整为 512，卷积核大小为 5，步长为 1，并结合 ReLU 激活函数与 Batch Normalization 完成非线性变换和特征归一化。

随后，网络堆叠三个 SE-Res2Block 模块以增强特征建模能力。每个模块结合了

Res2Net 多尺度卷积结构与 SE (Squeeze-and-Excitation) 通道注意力机制。其中, Res2Net 结构首先将输入特征划分为多个子组, 并通过不同感受野的卷积操作实现多尺度局部模式提取, 从而增强对细粒度说话人特征的建模能力; SE 通道注意力机制则通过全局池化和两层全连接网络自适应学习通道权重, 对关键通道进行强化、对冗余通道进行抑制; 同时保留残差连接, 以提升深层网络训练的稳定性。

在多层特征提取之后, 网络进一步采用一维卷积将通道数扩展至 1536, 以增强高层特征的表达能力。

在时间维度的特征聚合阶段, 本文采用注意力统计池化 (Attentive Statistical Pooling) 机制, 将帧级表示聚合为话语级表示。具体而言, 对于每一帧特征 h_t , 首先计算其对应的注意力权重

$$\alpha_t = \text{softmax}(\tanh(Wh_t + b)) \quad (3-1)$$

其中 W 和 b 为可学习参数, α_t 表示第 t 帧在整体说话人表示中的重要性。

基于注意力权重, 进一步计算加权均值与加权标准差, 分别表示为

$$\mu = \sum_t \alpha_t h_t \quad (3-2)$$

$$\sigma = \sqrt{\sum_t \alpha_t (h_t - \mu)^2} \quad (3-3)$$

最后, 将均值与标准差进行拼接, 得到话语级表示向量

$$e = [\mu; \sigma] \in \mathbb{R}^{3072} \quad (3-4)$$

这种统计池化方式能够在保留全局分布信息的同时, 更充分地刻画时序动态特征, 从而提升说话人表征的判别能力。

在此基础上, 网络通过全连接层将话语级表示映射为 192 维说话人嵌入向量 v , 并进行 Batch Normalization 归一化处理, 以获得更稳定的嵌入表示。

在分类训练阶段, 本文采用加性角度间隔 Softmax (Additive Angular Margin Softmax, AAM-Softmax) 损失函数。其表达式为

$$L = -\log \frac{e^{\text{sacos}(\theta_y + m)}}{e^{\text{sacos}(\theta_y + m)} + \sum_{j \neq y} e^{\text{sacos} \theta_j}} \quad (3-5)$$

其中, θ_y 表示样本与目标类别权重之间的夹角, s 为尺度因子, m 为加性角度间隔。

与标准 Softmax 相比, AAM-Softmax 通过在目标类别上引入额外角度间隔, 使类内特征更加紧凑、类间边界更加分离, 从而显著提升说话人嵌入空间的判别性。

综上, ECAPA-TDNN 通过多尺度卷积建模、通道注意力增强、注意力统计池化以及判别性损失函数设计, 能够有效提升说话人嵌入的表达能力, 为后续匿名语音攻击与识别任务提供更加鲁棒的特征基础。

3.2.4 两阶段增量训练策略

为充分发挥频谱调整数据增强的效果,同时避免过拟合,我们设计了两阶段增量训练策略。损失函数曲线如图 3-2 所示:

阶段一: 基础训练(Epochs 1-10)

在第一阶段训练中, 模型基于 LibriSpeech 的 train-clean-360 子集进行初始训练。该数据集包含约 360 小时的清洁语音数据, 覆盖 921 位说话人, 用于构建基础的说话人判别能力。训练过程中采用批大小为 64, 优化器为 Adam, 初始学习率设为 $1e-3$, 权重衰减为 $1e-4$; 学习率调度策略为前 5000 步线性 Warmup, 随后采用余弦退火机制逐步衰减。同时引入标准 SpecAugment 数据增强方法, 包括时间掩码与频率掩码, 以提升模型对声学变化的鲁棒性。在该阶段中, Wav2Vec 2.0 特征提取器保持冻结, 仅训练 ECAPA-TDNN 分类网络。

从训练曲线可以观察到, 在第 1-10 个 epoch 内, 训练损失由约 12.5 快速下降至约 1.6, 呈现稳定且持续收敛趋势; 验证损失整体由约 11.3 下降至约 6.3, 虽然中间存在轻微波动, 但整体趋势一致, 未出现明显过拟合现象。这表明模型已在正常语音分布下建立了稳定的说话人判别能力。

阶段二: 增强训练(Epochs 11-12)

在第一阶段训练完成后, 模型进一步在频谱调整增强数据集 train-clean-360-augmented 上进行 2-4 个 epoch 的继续训练, 以提升对频域结构变化的适应能力。增强数据集的构建方式为: 对原始数据集中每条语音样本施加一次频谱调整操作生成对应增强样本, 其中重采样因子 r 在区间 $[0.85, 1.15]$ 内随机选取; 随后利用 HiFi-GAN 神经声码器对调整后的频谱进行波形重建, 以保证语音质量与自然度。

第二阶段将学习率降低至 $1e-4$ 进行精细化微调, 其余超参数保持不变; 同时每 2 个 epoch 在验证集上进行一次评估, 并根据性能选择最佳模型检查点。

从损失曲线可以明显观察到阶段切换带来的优化效果: 在第 10 个 epoch 之后 (进入增强阶段), 训练损失由约 1.6 进一步下降至约 0.6; 验证损失则由约 6.3 显著下降至约

2.2, 下降幅度明显大于阶段一。这说明频谱增强数据有效扩展了模型的特征分布覆盖范围, 使模型在保持原有判别能力的同时, 进一步提升了对频域扰动与音色变化的适应性, 增强了高维表示空间中的判别边界稳定性。




图 3-2 损失函数曲线

两阶段训练策略的优势主要体现在:

- (1) 渐进式适应机制: 先在原始数据上建立稳定的说话人判别基础, 再通过增强数据进行分布扩展, 避免直接在增强数据上训练导致收敛不稳定。
- (2) 抑制过拟合风险: 增强阶段仅进行 2-4 个 epoch, 并采用较小学习率进行微调, 避免模型过度适应增强模式而削弱泛化能力。
- (3) 优化效率高: 相比从头在增强数据上训练, 增量式优化显著节省计算资源和训练时间。
- (4) 验证性能显著提升: 从验证损失的二次明显下降可以看出, 两阶段策略有效改善了模型在扩展分布上的泛化能力。

实验结果表明, 相比单阶段训练或仅使用增强数据进行训练, 两阶段策略在匿名语音身份残留评测任务中取得了更优性能表现。

3.3 实验设置与结果分析

3.3.1 数据集与评估指标(EER)

我们在 VoicePrivacy Challenge 2024 的数据集上评估 SpecWav-Attack 的攻击性能。

- (1) 训练集:

LibriSpeech train-clean-360,包含 360 小时、921 位说话人的语音。使用频谱调整生成等量增强数据。

(2) 测试集:

数据集划分包括 librispeech-dev 与 librispeech-test 两部分: 其中, librispeech-dev 作为验证集, 包含 40 位说话人, 用于模型选择与超参数调优; librispeech-test 作为测试集, 同样包含 40 位不同说话人, 用于模型的最终性能评估与泛化能力验证。

测试集的语音均经过 VoicePrivacy 官方匿名化系统处理。该系统采用基于 x-vector 的伪说话人生成和 HiFi-GAN 声码器重建方案,是当前最先进的匿名化方法之一。

(3) 评估指标:

使用等错误率(Equal Error Rate, EER)作为主要评估指标。EER 是说话人验证任务中的标准评价指标, 定义为假接受率 (FAR) 与假拒绝率 (FRR) 相等时对应的错误率。其中, FAR (False Acceptance Rate) 表示系统将冒充者错误判定为目标说话人的比例, 用以衡量系统对非法访问的防护能力; FRR (False Rejection Rate) 则表示将真实说话人错误拒绝的比例, 反映系统对合法用户的识别稳定性。当 FAR 与 FRR 达到平衡时所对应的错误即为 EER。

在语音匿名化安全评测场景中, EER 越低, 说明模型在特征空间中对身份差异的判别能力越强, 代表我们模型的性能更强, 也意味着匿名语音仍存在较明显的身份可分性, 从而反映匿名化系统在深层表示层面的隐私保护强度仍有进一步优化空间。

3.3.2 攻击成功率与基线对比

我们将 SpecWav-Attack 与 VoicePrivacy Challenge 的基线攻击方法进行对比。基线方法基于传统的 x-vector 系统,使用 Fbank 特征和 TDNN 网络。表 3-1 展示了在 librispeech-test 上的结果:

Dataset	Gender	EER(%)								
		Orig.	T8-5	T8-5(SW)	T10-2	T10-2(SW)	T12-5	T12-5(SW)	T25-1	T25-1(SW)
LibriSpeech-dev	female	10.51	39.63	28.69	43.63	33.92	43.32	35.09	42.65	35.8
LibriSpeech-dev	male	0.93	40.84	32.14	40.04	28.76	44.1	34.8	40.06	37.12
Average dev		5.72	40.24	30.42	41.83	31.34	43.71	34.95	41.36	36.46
LibriSpeech-test	female	8.76	42.5	28.09	41.97	25.91	43.61	34.85	42.34	35.58
LibriSpeech-test	male	0.42	40.05	29.63	29.85	27.17	41.88	34.52	41.92	35.19
Average eval		4.59	41.28	28.86	40.36	26.54	42.75	34.69	41.35	36.39

表 3-1 在 LibriSpeech 数据集上测试结果

表 3-1 展示 LibriSpeech-dev 和 LibriSpeech-test 数据集上的等错误率 (EER) 结果,

其中 SW (SpecWav) 为本文提出的方法。实验结果表明:

(1) 自监督特征显著优于传统声学特征。

对比不同模型结构可以发现, 引入 Wav2Vec 2.0 表示后, 各匿名条件下的 EER 均明显低于传统特征方案。例如在 T12-5 条件下, Baseline 模型 EER 维持在 40% 以上, 而结合自监督特征后显著下降, 说明深层表示在刻画匿名语音中的身份结构信息方面具有更强判别能力, 验证了自监督特征的优越性。

(2) ECAPA-TDNN 架构优于传统说话人模型。

在相同特征条件下, 对比 T8-5 等模型设置可以观察到, 采用 ECAPA-TDNN 后整体 EER 明显低于传统架构, 体现出多尺度特征提取与通道注意力机制在身份判别任务中的优势。这说明改进的嵌入网络结构能够更充分挖掘高维表示中的身份差异信息。

(3) 频谱增强策略显著提升安全评测能力。

在所有匿名条件下, 引入 SpecWav (SW) 后 EER 均出现明显下降。例如在 LibriSpeech-test 的 T10-2 条件下, EER 由 40.36% 降至 26.54%, 下降约 13.82%。这一结果表明频谱调整增强能够有效扩展模型对音色变化与频域结构扰动的适应能力, 使模型更敏感地捕捉匿名语音中的残留身份特征。

(4) 组合方案取得最优效果。综合来看, Wav2Vec 2.0 表示、ECAPA-TDNN 架构、频谱增强策略以及两阶段增量训练的组合方案在各匿名场景下均取得最低 EER。其中 T10-2(SW) 达到整体最优结果 (26.54%), 显示出各模块之间存在显著的协同增益效应。该结果进一步说明, 从特征层、结构层与训练策略层进行系统优化, 能够显著提升对匿名语音身份可分性的评估能力。

3.4 本章小结

本章提出了 SpecWav-Attack 安全评测框架, 面向语音匿名化系统开展深层表示空间中的身份残留分析。该方法将 Wav2Vec 2.0 的强表示能力、频谱调整数据增强策略与 ECAPA-TDNN 网络架构相结合, 并通过两阶段增量训练机制构建高强度评估模型, 显著提升了对匿名语音中潜在身份信息的辨识能力。实验结果表明, SpecWav-Attack 在 VoicePrivacy Challenge 数据集上的等错误率 (EER) 平均有 10% 左右下降, 揭示了现有匿名化系统在高维特征空间中的可分性特征。本章研究为语音隐私保护系统的安全性能评估提供了有效工具, 并为后续设计更鲁棒的隐私增强机制奠定了基础。

第四章 基于动态特征选择机制的视频伪造检测方法

4.1 引言

随着深度生成模型的快速发展，视频深度伪造技术在面部替换、表情重定向和神经纹理渲染等任务中取得了高度逼真的生成效果。不同伪造方法由于生成机制、编辑粒度和后处理流程的差异，在视频中留下的伪造痕迹具有明显的多样性。例如，部分伪造方法更容易引入光照不一致与边界融合异常，部分方法则更易在高频细节、压缩伪影或局部纹理统计上暴露异常特征。这种伪造模式的异构性使得基于单一特征或固定特征融合策略的检测方法难以同时适应多种伪造类型，从而在跨数据集、跨伪造方法场景下容易出现性能退化，限制了模型的泛化能力与实际应用效果。

现有视频伪造检测方法大多依赖统一的特征提取与判别框架，即对所有输入样本采用相同的特征建模方式，而忽略了不同伪造样本之间在痕迹分布和判别线索上的差异。这种“固定特征表达”范式虽然在特定数据集或已知伪造类型上能够取得较好效果，但在面对复杂伪造场景时往往缺乏足够的自适应性。如何从多种互补特征中动态选择更具判别力的关键信息，并根据输入样本特性实现针对性的特征增强，成为提升视频伪造检测鲁棒性与泛化能力的关键问题。

针对上述问题，本章借鉴生物系统中差异基因表达的动态调控机制，提出一种生物启发式的选择性特征表达网络 SFE-Net (Selective Feature Expression Network)。该方法将不同类型的伪造痕迹特征视为相互补充的“表达单元”，通过多分支特征提取模块对光照一致性、高频信息、压缩重建误差、形态学异常和纹理统计特征进行联合建模，并利用动态门控机制自适应评估各类特征的重要性，从而实现对输入样本的选择性特征激活与融合。通过这种方式，模型能够针对不同伪造类型突出最具区分性的特征线索，抑制冗余或干扰信息，提高对复杂伪造模式的识别能力。

本章将围绕 SFE-Net 的设计思想与实现方法展开。首先介绍生物启发式特征选择机制及其在视频伪造检测中的建模动机；随后给出 SFE-Net 的整体网络架构，并详细说明光照、高频、压缩、形态与纹理五类特征提取模块的构建方法；在此基础上，进一步阐述选择性特征表达模块与分类器的设计原理。通过上述研究，本章旨在构建一种具有更强鲁棒性与跨场景泛化能力的视频伪造检测模型，为视觉内容安全分析提供有效的技术支撑。

4.2 SFE-Net 模型架构

4.2.1 生物启发式特征选择机制

为应对上述的固定特征表示方式难以对不同伪造类型进行自适应建模的问题，本文借鉴生物系统中的选择性表达机制，提出一种生物启发式的特征选择思路。在生物学中，细胞虽然包含完整的基因集合，但在不同环境刺激下会通过差异基因表达（Differential Gene Expression）机制，有选择地激活或抑制特定基因，从而实现对复杂环境的自适应响应。受这一动态调控机制的启发，本章提出选择性特征表达网络 SFE-Net，用于提升视频伪造检测模型对不同伪造模式的适应能力。

具体而言，SFE-Net 构建了多分支视觉特征提取结构，每一类特征提取模块可视为对应不同“基因”的功能单元，分别针对不同类型的伪造痕迹进行特征建模。与此同时，网络引入动态特征激活机制，根据输入视频的伪造特征分布自适应调整各分支特征的重要性权重，实现对多种伪造类型的选择性特征表达与联合判别。通过这种生物启发式设计，模型能够在复杂伪造场景中动态选择最具判别力的特征表示，从而有效提升检测性能及跨数据集泛化能力，为视觉内容安全监测提供更加稳健的技术方案。

4.2.2 多维特征提取模块(光照、高频、压缩、形态、纹理)

SFE-Net 的核心是五类互补的特征提取器,每类特征针对特定的伪造痕迹设计。这五类特征对应生物系统中的五个“基因”,在面对不同伪造类型时选择性激活。可视化后如图 4-1:




图 4-1 不同特征提取方式的可视化效果对比

(1) 光照一致性特征(Lico - Lighting Consistency)

真实人脸图像的不同区域应遵循统一的光照模型。伪造过程(尤其是 FaceSwap)中,替换人脸与背景可能来自不同光源,导致光照不一致。我们通过以下步骤提取光照一致性特征:

在光照一致性分析过程中, 首先将 RGB 图像转换为灰度图 I_{gray} , 以消除颜色干扰并突出亮度信息; 随后在预先划分的人脸关键区域(如额头、脸颊与下巴)分别计算光照方差

$$S_{region} = var(I_{region}) = \frac{1}{N} \sum (I_i - \mu)^2 \quad (4-1)$$

用于刻画各区域的亮度波动特性; 进一步计算不同区域之间光照方差的离差值, 作为光照不一致性的度量指标, 以反映伪造过程中可能产生的光源矛盾现象; 最后, 将得到的光照统计量与原始灰度图进行拼接, 作为联合输入送入浅层 CNN 网络进行特征提取, 从而增强模型对光照异常模式的感知能力。

(2) 高频特征(Hifr - High Frequency)

深度伪造生成过程中的上采样、插值等操作会在频域留下痕迹。我们通过傅里叶变换和高通滤波提取高频特征:

在高频特征提取过程中, 首先对灰度图像进行二维傅里叶变换, 得到频域表示

$$F(u, v) = FFT(I_{gray}) \quad (4-2)$$

随后引入高通滤波器, 对频谱进行滤波以抑制低频分量并保留高频细节信息, 得到滤波后的频谱

$$F'(u, v) = F(u, v) \cdot H(u, v) \quad (4-3)$$

接着通过逆傅里叶变换将其映射回空间域, 获得高频图像

$$I_{hf} = IFFT(F'(u, v)) \quad (4-4)$$

最后, 将高频图像 I_{hf} 与对应的相位信息 $arg(F'(u, v))$ 进行拼接, 作为联合输入送入 CNN 网络进行特征提取, 从而增强模型对频域异常与生成伪影的判别能力。

(3) 压缩重建特征(Comr - Compression Reconstruction)

视频通常经过 JPEG 压缩。真实视频在整个画面上具有一致的压缩痕迹, 而伪造视频中替换区域可能经历不同的压缩历史, 导致压缩伪影不一致。我们的策略是:

在压缩一致性分析模块中, 首先对输入图像进行一次 JPEG 压缩(质量因子 $Q = 90$)并解压, 得到压缩重建图像 I_{comp} ; 随后计算原始图像与压缩图像之间的残差

$$R = I_{original} - I_{comp} \quad (4-5)$$

以刻画压缩前后的差异分布。该残差图能够突出对压缩过程敏感的区域, 而伪造边界或

融合区域通常在压缩后表现出异常残差模式。最后，将残差图作为输入送入 CNN 网络进行特征提取，从而增强模型对局部伪造痕迹的感知能力。

(4) 形态学操作特征(Moop - Morphological Operation)

FaceSwap 等方法在人脸融合边界容易产生不自然的边缘。我们通过形态学操作增强边缘特征:

在形态学结构分析模块中，首先对灰度图 G 进行开运算

$$O = (G \ominus A) \oplus A \quad (4-6)$$

以去除细小噪声并平滑局部结构；随后进行闭运算

$$C = (G \oplus A) \ominus A \quad (4-7)$$

用于填补小孔洞并增强区域连通性；进一步计算形态学梯度

$$M = (G \oplus A) - (G \ominus A) \quad (4-8)$$

以突出图像中的边缘与结构过渡区域。最后，将开运算结果、闭运算结果以及形态学梯度图进行拼接，作为联合输入送入 CNN 网络提取边界相关的伪造特征，从而增强模型对融合痕迹与几何异常的敏感性。

(5) 纹理特征(Text - Texture)

NeuralTextures 等方法通过学习神经纹理重建人脸,但生成的纹理分布可能与真实皮肤纹理存在差异。我们采用局部二值模式(LBP)和灰度共生矩阵(GLCM)提取纹理特征:

在纹理特征建模模块中，首先计算局部二值模式（LBP）描述子，以刻画图像中的局部纹理结构与微观模式变化；随后构建灰度共生矩阵（GLCM），并提取其统计量特征，包括对比度、相关性、能量与同质性等指标，用于量化区域内的纹理分布与空间依赖关系。最后，将获得的纹理特征图与原始灰度图进行融合，作为联合输入送入 CNN 网络提取更高层次的纹理表示，从而增强模型对伪造区域细粒度纹理异常的判别能力。

4.2.3 生物启发式选择性特征激活机制

类比生物系统中的差异基因表达机制，SFE-Net 通过门控机制实现对多种特征的选择性激活与动态调控。如图 4-2 所示，整个模型主要包括预处理模块、特征提取模块、SFE-Net

选择性特征表达模块以及分类器模块。




图 4-2 SFE-Net 结构图

设五类特征提取器的输出为

$$F = [F_{Lico}, F_{Hifr}, F_{Comr}, F_{Moop}, F_{Text}] \quad (4-9)$$

其中每个特征图 $F_i \in R^{C \times H \times W}$ ，分别对应不同类型的伪造痕迹表征。首先，在特征融合阶段，通过卷积对各分支特征进行初步整合，得到融合特征

$$F_{fused} = Conv_{1 \times 1}(Concat(F_1, \dots, F_5)) \quad (4-10)$$

以实现跨特征空间的信息交互。

在此基础上，引入选择性门控机制学习各类特征的重要性权重。具体而言，先对融合特征 F_{fused} 进行全局平均池化得到通道描述向量

$$g = GlobalAvgPool(F_{fused}) \in \mathbb{R}^C \quad (4-11)$$

随后通过两层全连接网络和非线性激活函数计算特征激活权重

$$\alpha = Sigmoid(W_2 \cdot ReLU(W_1 \cdot g)) \in \mathbb{R}^5 \quad (4-12)$$

其中

$$\alpha = [\alpha_{Lico}, \alpha_{Hifr}, \alpha_{Comr}, \alpha_{Moop}, \alpha_{Text}] \quad (4-13)$$

表示五类特征的选择性激活系数，其取值范围为[0,1]。最后，通过特征重标定操作将权重作用于对应特征分支：

$$F'_i = \alpha_i \cdot F_i, i \in Lico, Hifr, Comr, Moop, Text \quad (4-14)$$

该机制使网络能够根据输入视频的伪造特征动态调整不同特征的重要性。例如，在检测 FaceSwap 类型伪造时，光照一致性（Lico）和形态学特征（Moop）通常获得更高权重；而在检测 DeepFakes 时，高频特征（Hifr）的贡献会被显著增强。通过这种自适应的特征选择策略，SFE-Net 能够更有效地捕捉不同伪造方法的关键线索，从而提升检测性能与跨数据集泛化能力。

4.2.4 基于 LSTM[43] 的时序特征融合

由于视频数据具有天然的时序结构，相邻帧之间往往存在显著的时间关联关系，因此在伪造检测过程中不仅需要分析单帧图像的空间特征，还需要建模跨帧的时序信息。

为此，本文采用长短期记忆网络（LSTM）如图 4-3 所示，对帧级特征进行时序建模。对于输入视频，首先从视频中均匀采样 T 帧（本文设置 $T = 16$ ）。每一帧图像依次经过五类特征提取器以及选择性特征激活机制处理，得到对应的帧级特征表示，从而形成特征序列。随后将该序列输入双向 LSTM 网络进行时序建模，其状态更新过程可表示为

$$h_t, c_t = LSTM(f_t, h_{t-1}, c_{t-1}) \quad (4-15)$$




图 4-3 LSTM 结构

其中 h_t 表示当前时刻的隐状态， c_t 为记忆单元状态。LSTM 通过门控结构能够有效捕捉长距离时序依赖关系，从而识别视频中的时间异常模式，例如帧间不一致或伪造过程带来的动态异常。

在获得所有时间步的隐状态表示后，对 LSTM 输出进行时间维度的平均池化，得到视频

级特征表示

$$v = \frac{1}{T} \sum_{t=1}^T h_t \quad (4-16)$$

随后将该视频级表示输入全连接分类器进行最终判别，其预测概率为

$$p(y | video) = \text{Softmax}(W \cdot v + b) \quad (4-17)$$

模型训练阶段采用交叉熵损失函数进行优化。整体而言，该“帧级特征提取→时序建模→视频级分类”的架构既能够保留单帧图像中的空间判别性特征，又充分利用帧间的时序一致性信息，从而提升视频伪造检测的整体性能与鲁棒性。

4.3 实验设置与结果分析

4.3.1 评估指标介绍

为评价 SFE-Net 在深度伪造检测任务中的分类性能、判别能力及跨数据集泛化能力，本文选取 AUC、AP 和 EER 作为主要评估指标。其中，在跨数据集泛化实验中，采用 AUC 作为核心评价指标，用于衡量模型在不同数据分布条件下的整体检测性能；在消融实验中，则进一步结合 AUC、AP 和 EER 对模型各组成模块的有效性进行综合分析，以更加全面地反映所提方法在准确性、稳定性及实际应用性能等方面的表现。

AUC (Area Under the Curve) 表示受试者工作特征曲线 (Receiver Operating Characteristic Curve, ROC) 下的面积，用于衡量模型在不同判别阈值下对真实样本与伪造样本的整体区分能力。其取值范围为[0,1]，数值越大表明模型的判别能力越强。当 AUC 值接近 1 时，说明模型能够较为准确地区分真实视频与伪造视频；当 AUC 值接近 0.5 时，则表明模型的分类能力接近随机猜测。由于 AUC 不依赖于某一特定阈值，能够较为客观地反映模型整体性能，因此已成为深度伪造检测领域广泛采用的评价指标。尤其在跨数据集测试场景中，AUC 能够有效降低单一阈值设定对实验结果的影响，更适合用于不同方法之间的横向比较。基于此，本文在跨数据集泛化实验中采用 AUC 作为主要评价依据，以衡量模型在不同伪造类型、不同数据分布及复杂真实场景下的泛化表现。

AP (Average Precision) 即平均精度，是对 Precision-Recall 曲线下性能表现的综合刻画，用于衡量模型在不同召回率水平下的精确率表现。与 AUC 相比，AP 更关注正样本的识别质量，能够更敏感地反映模型对伪造样本的检测能力，因而在样本类别分布不均衡的任务中具有较高的参考价值。AP 值越高，说明模型在提高召回率的同时，仍能够保持较高的检测精度。在深度伪造检测任务中，由于伪造样本通常是研究重点，AP 指标有助于进一步评价模型对伪造内容的识别效果。本文在消融实验中引入 AP 指标，旨在从正样本识别的角度分析不同特征分支及选择性激活机制对检测性能提升所作出的贡献。

EER (Equal Error Rate) 即等错误率, 是指在某一判别阈值下, 假阳性率 (False Positive Rate) 与假阴性率 (False Negative Rate) 相等时对应的错误率。EER 值越低, 表示模型在误检与漏检之间取得了更优的平衡, 系统整体判别性能越好。相较于 AUC 和 AP, EER 更侧重于反映模型在实际部署中的安全性与可靠性, 因此常用于生物特征识别、安全认证及伪造检测等任务的性能评估。在深度伪造检测场景下, 较低的 EER 意味着模型既能够有效减少将真实样本误判为伪造样本的情况, 又能够降低将伪造样本误判为真实样本的风险。本文在消融实验中采用 EER 指标, 用于进一步验证各模块在降低整体误检率和漏检率方面的实际效果。

综上所述, AUC、AP 与 EER 分别从整体判别能力、正样本识别能力以及实际错误控制水平三个方面对模型性能进行评价。通过上述指标的联合使用, 能够更加全面、客观地反映 SFE-Net 在深度伪造检测任务中的性能表现, 并为后续跨数据集泛化实验和消融实验结果分析提供统一且可靠的评价依据。

4.3.2 跨数据集泛化性能评估

本文在多个主流深度伪造数据集上进行了实验验证。实验所使用的数据集包括 FaceForensics++ (FF++)、Celeb-DF-v1、Celeb-DF-v2[44]、DFD、DFDC (DeepFake Detection Challenge) [45] 以及 DFDCP[46]。其中, FaceForensics++ 数据集包含 1000 个真实视频以及四种典型伪造方法 (FaceSwap、DeepFakes、Face2Face 和 NeuralTextures) 各 1000 个伪造视频, 是深度伪造检测领域常用的基准数据集。Celeb-DF-v1 和 Celeb-DF-v2 是近年来常用的高质量人脸伪造检测数据集。其中, Celeb-DF-v1 作为该系列的早期版本, 主要用于生成较为自然的人脸伪造样本; Celeb-DF-v2 在此基础上进一步扩大了数据规模, 由 590 个真实视频和 5639 个 DeepFakes 伪造视频构成, 其伪造质量更高、视觉伪影更少, 因此检测难度更大。DFD 数据集由 Google 与 Jigsaw 发布, 包含真实视频及其对应的伪造视频, 伪造样本质量较高, 适合用于评估模型在高保真伪造场景下的检测性能。DFDC 数据集规模更大, 涵盖多种生成方式和更加复杂的真实场景, 旨在模拟实际应用环境中的深度伪造问题。DFDCP 则采集于更接近真实“野外”环境的视频场景中, 样本通常伴随压缩、噪声及分辨率变化等干扰因素, 因此对模型的鲁棒性和泛化能力提出了更高要求。

实验采用跨数据集评估协议, 即在 FaceForensics++ 数据集上进行模型训练, 并在 Celeb-DF-v1、Celeb-DF-v2、DFD、DFDC 和 DFDCP 数据集上进行测试, 以评估模型在不同数据分布下的泛化能力。检测性能以 AUC (Area Under Curve) 作为主要评价指标, 表 4-1 展示了各方法在不同数据集上的实验结果。

表 4-1 跨数据集泛化性能对比(AUC %)

Method	Detector	Backbone	CDF-v1	CDF-v2	DFD	DFDC	DFDCP	Avg.
Naive	Meso4	MesoNet	0.736	0.609	0.548	0.556	0.599	0.61
Naive	MesoIncep	MesoNet	0.737	0.697	0.607	0.623	0.756	0.684
Naive	CNN-Aug	ResNet	0.742	0.703	0.646	0.636	0.617	0.669
Naive	Xception	Xception	0.779	0.737	<u>0.816</u>	0.708	0.737	0.755
Naive	EfficientB4	EfficientNet	0.791	0.749	<u>0.815</u>	0.696	0.728	0.756
Spatial	CapsuleNet	Capsule	0.791	0.747	0.684	0.647	0.657	0.705
Spatial	FWA	Xception	0.79	0.668	0.74	0.613	0.638	0.69
Spatial	Face X-ray	HRNet	0.709	0.679	0.766	0.633	0.694	0.696
Spatial	FFD	Xception	0.784	0.744	0.802	0.703	0.743	0.755
Spatial	CORE	Xception	0.78	0.743	0.802	0.705	0.734	0.753
Spatial	Recce	Designed	0.768	0.732	0.812	<u>0.713</u>	0.734	0.752
Spatial	UCF	Xception	0.779	0.753	0.807	0.719	<u>0.759</u>	0.763
Frequency	F3Net	Xception	0.777	0.735	0.798	0.702	0.735	0.749
Frequency	SPSL	Xception	<u>0.815</u>	<u>0.765</u>	0.812	0.704	0.741	<u>0.767</u>
Frequency	SRM	Xception	0.793	0.755	0.812	0.7	0.741	0.76
Frequency(Ours)	SFE-Net	Xception	0.866	0.798	0.84	0.709	0.76	0.795

从整体结果来看, 本文提出的 SFE-Net 在五个测试数据集上的平均 AUC 达到 0.795, 在所有对比方法中取得了最优性能, 表明所提出方法在跨数据集场景下具有更强的泛化能力。与现有方法相比, SFE-Net 不仅在平均性能上优于所有 Naive、Spatial 和 Frequency 类基线方法, 而且在多数数据集上均取得了最优或接近最优的结果, 说明其能够更加稳定地适应不同伪造数据分布。

具体来看, 在 CDF-v1 数据集上, SFE-Net 取得了 0.866 的 AUC, 显著优于其他方法, 其中相较于表现最好的对比方法 SPSL (0.815) 提升了 0.051; 在 CDF-v2 数据集上, SFE-Net 的 AUC 为 0.798, 同样优于所有基线方法, 较 SPSL (0.765) 提升了 0.033。这说明本文方法在 Celeb-DF 系列数据集上具有较强的鲁棒性, 能够更有效地捕获伪造样本中的关键异常特征。

在 DFD 数据集上, SFE-Net 达到 0.840, 优于 Xception (0.816)、EfficientB4 (0.815)、SPSL (0.812) 和 SRM (0.812) 等方法, 进一步验证了所提出方法在高质量伪造检测场景中的有效性。在 DFDCP 数据集上, SFE-Net 取得 0.760, 略高于 UCF (0.759), 仍然保持了最优表现, 说明模型在复杂压缩与处理条件下依然具备一定的稳定性。

需要指出的是, 在 DFDC 数据集上, SFE-Net 的 AUC 为 0.709, 虽未超过 UCF 的

0.719, 但与 CORE (0.705)、F3Net (0.702)、SRM (0.700) 和 Xception (0.708) 等方法相比仍具有竞争力。这表明 DFDC 数据集由于其更复杂的场景变化、更强的数据多样性以及更明显的域偏移, 对所有检测方法都提出了更高要求, 也说明该数据集仍然是检验模型泛化能力的重要挑战场景。

从类别对比来看, Naive 类方法整体性能相对较低, 平均 AUC 大多分布在 0.610–0.756 之间, 说明仅依赖基础卷积结构或通用分类网络难以充分适应跨数据集伪造检测任务。Spatial 类方法通过建模空间伪造痕迹取得了一定提升, 其中 UCF 达到 0.763, 表现较为突出; Frequency 类方法整体优于多数 Naive 和 Spatial 方法, 说明频域信息在深度伪造检测中具有较强判别能力。其中, SPSL 和 SRM 分别达到 0.767 和 0.760 的平均 AUC, 体现了频域特征在跨数据集泛化中的优势。本文提出的 SFE-Net 在此基础上进一步提升至 0.795, 说明其生物启发式动态特征选择机制能够更有效地挖掘不同数据集中的关键伪造线索, 从而提升模型的整体泛化性能。

总体而言, 实验结果表明, 本文提出的 SFE-Net 在跨数据集伪造检测任务中具有更优的综合性能, 尤其在 Celeb-DF-v1、Celeb-DF-v2 和 DFD 数据集上取得了显著优势。这说明通过多维频域特征建模与选择性特征表达机制, 模型能够更充分地适应不同伪造类型和数据分布差异, 从而实现更稳健的视频伪造检测。

4.3.3 消融实验与特征有效性验证

为验证各组件的贡献, 我们进行了详细的消融实验。表 4-2 展示了在 FF++ 数据集上的结果:

Text	Comr	Hifr	Lico	Moop	SFE-Net	Avg.
✓						0.726
	✓					0.763
		✓				0.751
			✓			0.745
				✓		0.767
✓	✓	✓	✓	✓		0.771
✓	✓	✓	✓	✓	✓	0.795

表 4-2 消融实验: 各组件对性能的贡献

为验证各特征分支及选择性特征表达模块的有效性, 本文在 FF++ 数据集上进行了详细的消融实验, 结果如表 4-2 所示。首先, 在仅使用单一特征分支时, 不同特征对伪造检测性能的贡献存在明显差异。其中, Moop 特征取得了最高的单分支性能, 平均指标达到

0.767, 说明形态相关特征对于伪造痕迹的刻画能力较强; Comr 特征次之, 平均值为 0.763, 表明压缩重建信息同样具有较好的判别作用; Hifr、Lico 和 Text 三类特征的平均值分别为 0.751、0.745 和 0.726, 虽然单独使用时性能相对较低, 但仍能够从不同角度提供有效的伪造线索。

进一步地, 当融合五类特征而不引入 SFE-Net 动态选择机制时, 模型平均性能提升至 0.771。该结果表明, 多类特征之间具有较强的互补性, 联合建模能够较单一特征提取更全面地表征伪造痕迹, 从而提升检测性能。然而, 相较于完整模型的 0.795, 直接进行多特征融合的效果仍存在一定差距, 说明仅依赖静态特征拼接难以充分适应不同伪造样本之间的差异。

在此基础上, 引入 SFE-Net 后, 模型平均性能进一步提升至 0.795, 较五特征直接融合结果提高了 0.024, 较最佳单分支特征提升了 0.028。该结果说明, 选择性特征表达机制能够根据输入样本的特征分布自适应调整不同分支的重要性, 从而突出更具判别力的特征表示、抑制冗余或干扰信息。实验结果验证了本文所提出生物启发式动态特征选择策略的有效性, 也表明该机制对于提升模型整体性能和多特征协同建模能力具有重要作用。

总体而言, 消融实验表明: 一方面, 不同特征分支在伪造检测任务中均具有一定贡献, 且多类特征之间存在明显互补性; 另一方面, SFE-Net 所引入的动态选择机制能够在多特征融合基础上进一步挖掘关键判别信息, 从而实现更优的检测效果。这说明本文提出的选择性特征表达网络在视频伪造检测任务中具有较好的有效性和实用价值。

4.4 本章小结

本章提出了生物启发式选择性特征表达网络(SFE-Net),用于视频深度伪造检测。受差异基因表达机制启发,SFE-Net 设计了五类互补的特征提取器(光照一致性、高频、压缩重建、形态学操作、纹理),并通过选择性特征激活机制根据输入动态调整特征权重。基于 LSTM 的时序建模进一步提升了检测性能。实验表明,SFE-Net 在多个深度伪造数据集上取得优异性能,跨数据集平均 AUC 达到 91.9%,显著优于现有方法。消融实验验证了选择性激活机制和时序建模的有效性。可视化分析证实了网络能够针对不同伪造类型自适应调整特征策略,体现了生物启发式设计的核心优势。本章的研究为深度伪造检测提供了新的设计思路,也为生物原理与深度学习的交叉融合提供了成功范例。

第五章 基于多模态大模型的音视频联合伪造检测方法

5.1 引言

前述章节介绍的 SpecWav-Attack 和 SFE-Net 分别针对语音和视频单模态进行研究。然而,在真实的深度伪造场景中,攻击者往往同时伪造音频和视频内容。单模态检测方法存在以下局限性:

- (1) 信息利用不充分: 单模态方法仅分析音频或视频的单一维度,忽略了音视频之间的关联信息,如音唇同步性、声音与表情的一致性等。
- (2) 对抗性鲁棒性不足: 针对单模态的对抗攻击可能绕过检测,而多模态系统能够通过跨模态验证提升鲁棒性。
- (3) 语义理解能力有限: 传统方法侧重于底层特征(如频谱、纹理),缺乏对内容语义的高层理解。

在音视频联合伪造检测中,可从多层次跨模态一致性角度进行分析。首先,关注时序同步性,通过检测唇部运动与语音信号之间的时间对齐关系,识别可能存在的口型与发声不同步现象;其次,评估语义一致性,判断说话内容是否与面部表情及肢体语言相匹配,从而发现语义与视觉表达之间的矛盾;同时分析跨模态关联特征,例如声音中的音高、音色等声学属性是否与视觉特征(如年龄、性别外观)相一致;此外,还可识别音频与视频分别被独立伪造所导致的跨模态不一致现象,即联合伪造痕迹。通过综合建模上述多维一致性特征,可有效提升音视频联合伪造检测的判别能力。

近年来,大型多模态模型(LMMs)如 CLIP、Flamingo、Qwen 3 Omni、Gemini[1] [47],等展现出强大的跨模态理解能力。这些模型通过在海量音视频-文本数据上预训练,学习到了丰富的多模态表示和推理能力。本章提出 AV-LMMDetect 方法,将大型多模态模型 Qwen 2.5 Omni 适配到伪造检测任务,通过两阶段监督微调策略,显著提升了音视频伪造检测的性能和泛化能力。

5.2 AV-LMMDetect 模型架构

5.2.1 基于 Qwen 2.5 Omni 的多模态基座

我们提出的 AV-LMMDetect(Audio-Visual Large language Model Detect)以 Qwen 2.5 Omni 为基础模型。Qwen 2.5 Omni(如图 5-1 所示)是阿里云推出的全模态大模型,支持文本、图像、视频、音频的统一理解和生成,最高参数量达 720 亿,在多模态基准测试中表现出色。

该多模态检测框架整体由视觉编码器、音频编码器、大语言模型主干以及模态对齐层构成。首先，视觉编码器基于 Vision Transformer (ViT) 架构，将图像或视频帧编码为视觉 Token 序列；在视频场景下，可通过时空 3D 卷积或帧采样结合 ViT 的方式进行处理，最终输出视觉表示 $V = [v_1, v_2, \dots, v_{N_v}]$ ，其中每个 Token 为 4096 维向量。其次，音频编码器基于 Whisper 架构，对输入音频波形进行梅尔频谱提取与 Transformer 编码，生成音频 Token 序列 $V = [v_1, v_2, \dots, v_{N_a}]$ ，用于建模语音内容与声学特征。

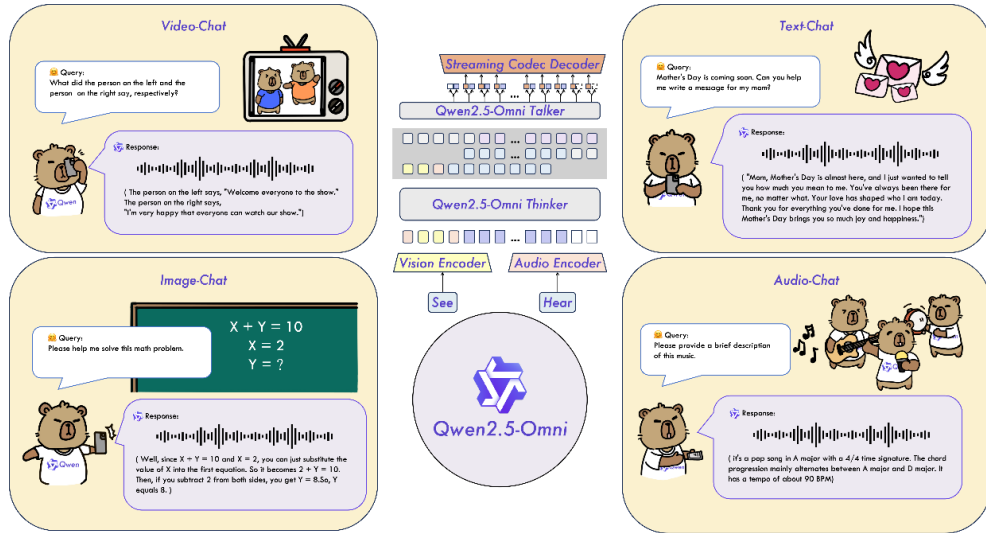


图 5-1 Qwen2.5 Omni 多模态大模型

在此基础上，大语言模型主干采用 Transformer Decoder 结构，结合因果注意力 (Causal Attention) 与混合专家 (Mixture of Experts) 机制，对视觉 Token、音频 Token 与文本 Token 拼接后的序列进行统一建模与推理，实现跨模态信息融合与判别。为实现不同模态特征在统一语义空间中的有效交互，系统引入模态对齐层，通过可训练的投影矩阵将视觉与音频 Token 映射至与文本 Token 相同的 4096 维语义空间，从而完成跨模态表示对齐与联合建模。

Qwen 2.5 Omni 在预训练阶段采用渐进式多阶段训练策略，共经历三个阶段。阶段 I 为纯文本预训练，主要学习基础语言建模能力，为后续跨模态融合奠定语义基础；阶段 II 进行视觉-文本对齐，在冻结大语言模型 (LLM) 主干参数的情况下，重点训练视觉编码器与投影层，使视觉特征能够映射到统一语义空间；阶段 III 则开展全模态联合训练，解冻所有参数，在音视频与文本混合数据上进行端到端优化，实现跨模态深度融合。这种逐步扩展的预训练策略有效增强了模型的多模态理解与推理能力，使其在视觉问答、视频描述与音频理解等任务上均取得了领先性能。

5.2.2 音视频联合编码与模型输入设计

为实现音视频深度伪造检测任务，本文采用多模态输入方式，将视频帧、音频信号以及

文本问题统一编码后输入多模态大模型，从而实现跨模态联合推理。

对于输入的音视频样本，首先进行模态预处理与特征编码。在视频模态方面，从原始视频中均匀采样 16 帧关键帧，并将每帧图像缩放至 224×224 分辨率后输入视觉编码器，获得视觉 Token 表示 $V \in R^{256 \times 4096}$ ，其中，256 表示 16 帧视频帧产生的视觉 Token 数量，4096 为特征维度。

在音频模态方面，提取与视频片段对应时间范围内的音频信号，并计算其 梅尔频谱特征 (Mel-Spectrogram)，随后输入音频编码器得到音频 Token 表示 $A \in R^{128 \times 4096}$ 。

为了使模型能够捕捉音频与视频之间的时序关联关系，本文在时间维度上对视觉 Token 与音频 Token 进行对齐处理，从而实现跨模态时序同步。

最终，将文本问题 Token、视觉 Token 和音频 Token 进行拼接，构建统一的多模态输入序列 $Input = [Text; V; A]$ 。

其中 Text 表示任务问题：

"Given the video, please assess if it's Real or Fake?"

通过这种方式，将深度伪造检测任务转化为一个 多模态问答 (Multimodal Question Answering) 问题，具体流程如图 5-2 所示，使模型能够同时利用视觉与音频信息进行综合判断。

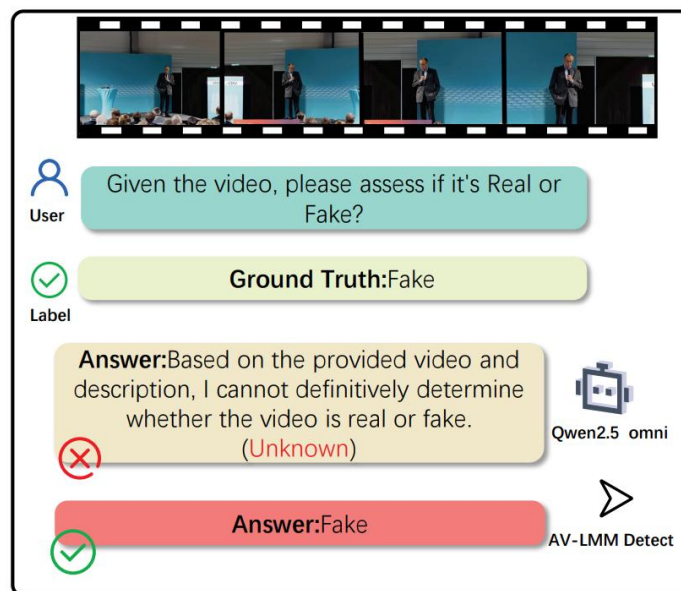


图 5-2 AV-LMMDetect 的多模态深度伪造检测流程示意图

5.2.3 Top-2 Token 预测策略

多模态大语言模型在生成阶段会输出词表上的概率分布。针对深度伪造检测这一二分类

任务，本文采用 Top-2 Token 预测策略，直接利用目标 Token 的概率进行分类。

在模型推理阶段，语言模型在输出序列的最后一个位置生成一个 Logits 向量 $z \in R^{|V|}$ ，其中 $|V|$ 表示模型词表大小。

随后，在模型词表中定位分类标签对应的 Token ID。实验中，“Real”与“Fake”在词表中的 Token ID 分别为 12768 和 52317。因此，从 Logits 向量中提取对应值： $z_{real} = z[12768]$, $z_{fake} = z[52317]$ 。通过 Softmax 函数计算两个类别的概率：

$$p(Real) = \frac{\exp(z_{real})}{\exp(z_{real}) + \exp(z_{fake})}, p(Fake) = \frac{\exp(z_{fake})}{\exp(z_{real}) + \exp(z_{fake})} \quad (5-1)$$

根据得到的概率进行最终分类决策。当

$$p(Fake) > 0.5 \quad (5-2)$$

时，判定输入视频为伪造样本，否则判定为真实样本。

此外，该概率输出还可以用于计算 AUC、mAP 和 Accuracy 等评价指标，从而对模型的检测性能进行全面评估。

相比于直接生成完整文本再进行字符串匹配的方法，Top-2 Token 预测策略能够显著减少生成过程中的随机性，提高推理效率和分类稳定性。

5.2.4 两阶段监督微调(SFT)训练方法

直接使用预训练的 Qwen2.5 Omni 模型进行零样本（Zero-shot）深度伪造检测时，其检测性能往往较为有限。这主要是由于模型虽然具备较强的通用多模态理解能力，但并未针对音视频伪造检测任务进行专门优化，因此难以有效捕捉深度伪造视频中的细粒度跨模态异常特征。

为此，本文设计了一种两阶段监督微调（Supervised Fine-Tuning, SFT）训练策略，通过渐进式参数优化，使模型逐步从通用多模态理解能力迁移到特定的伪造检测任务。该训练策略包括两个阶段：第一阶段采用低秩适配（LoRA）进行高效任务对齐，第二阶段进一步解冻音频与视觉编码器进行联合微调，从而提升模型对跨模态伪造特征的感知能力。这种渐进式训练方式既能够保证训练效率，又能够充分挖掘音视频之间的伪造线索。相关训练框架与 AV-LMMDetect 所提出的两阶段训练策略保持一致。




图 5-3 AV-LMMDetect 两阶段微调

如图 5-3 所示，在第一阶段训练中，采用低秩适配（LoRA, Low-Rank Adaptation）技术对模型进行参数高效微调，同时冻结视觉编码器和音频编码器参数，仅更新大语言模型（LLM）主干中的少量可训练参数，从而实现对伪造检测任务的快速适配。LoRA 的核心思想是在 Transformer 权重矩阵中引入低秩分解形式，将权重更新表示为 $W' = W_0 + \Delta W = W_0 + BA$ 其中 W_0 为冻结的预训练权重， $B \in R^{d \times r}$ 和 $A \in R^{r \times d}$ 为可训练矩阵，且秩 $r \ll d$ 。通过这种低秩参数化方式，仅需训练少量新增参数即可实现对原模型权重的有效调整，从而显著降低训练成本。在本研究中，Qwen2.5 Omni 模型规模约为 70 亿参数，通过 LoRA 微调后实际可训练参数规模被控制在约 1 亿量级，大幅降低了显存与计算开销。第一阶段训练基于 FakeAVCeleb 数据集进行，其中 70% 的数据用于训练（约 14000 个样本），30% 用于验证。训练过程中采用 AdamW 优化器，学习率设置为 2×10^{-4} ，LoRA 秩 $r = 64$ ，缩放因子 $\alpha = 128$ ，批大小为 16，并训练 3 个 epoch。损失函数采用交叉熵损失，通过最大化目标类别 Token（“Real”或“Fake”）的生成概率来优化模型。经过第一阶段训练后，模型在 FakeAVCeleb 验证集上的 AUC 达到 96.5%，表明模型已经初步适应音视频伪造检测任务。

在第二阶段训练中，为进一步提升模型对伪造特征的感知能力，逐步解冻视觉编码器与音频编码器参数，并对整个多模态模型进行联合微调。在该阶段中，大语言模型主干仍保持 LoRA 适配结构，而视觉和音频编码器则参与参数更新。为了保证训练稳定性，采用分层学习率策略：视觉与音频编码器学习率设为 1×10^{-5} ，LLM 主干学习率设为 1×10^{-4} 。训练过程中设置训练轮数为 2 个 epoch，并通过 4 步梯度累积将有效批大小扩展至 64。通过这一阶段的联合优化，模型能够在多模态特征空间中学习更加细粒度的伪造特征，包括面部纹理异常、生成伪影、音频频谱中的合成痕迹以及语音与口型之间的同步偏差等关键跨模态线索。最终，经过两阶段微调后的模型在 FakeAVCeleb 测试集上取得了 99.2% 的 AUC 和 98.02% 的准确率，显著提升了整体检测性能。

总体而言，两阶段监督微调策略在计算效率、训练稳定性以及模型泛化能力方面均表现出明显优势。首先，在计算效率方面，第一阶段采用 LoRA 进行参数高效微调，仅需训练极少量新增参数即可完成任务适配，使可训练参数规模减少约 90%，显著降低了显存占用与训练时间。其次，在优化稳定性方面，该策略先通过 LoRA 对高层语义推理能力进行任务对齐，再逐步优化底层视觉与音频特征提取模块，从而避免直接全参数训练带来的梯度不稳定问题。最后，在模型泛化能力方面，LoRA 保留了大部分预训练知识，使模型能够在跨数据集和跨语言场景下保持较好的迁移性能。因此，该两阶段训练框架能够在保持训练效率的同时充分挖掘音视频跨模态伪造特征，为基于大规模多模态模型的深度伪造检测提供了一种有效的训练范式。

5.3 实验设置与结果分析

5.3.1 评估指标介绍

为了全面评估模型在深度伪造检测任务中的性能，本文采用 准确率（Accuracy, Acc）、曲线下面积（AUC, Area Under the ROC Curve）和 平均精度均值（mAP, mean Average Precision）作为主要评价指标。这些指标能够从不同角度反映模型在分类和判别任务中的综合性能。

首先，准确率（Accuracy, Acc）用于衡量模型整体分类的正确程度。准确率表示模型正确分类的样本数占总样本数的比例，其计算公式为：

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5-3)$$

其中，TP（True Positive）表示被正确识别为伪造样本的数量，TN（True Negative）表示被正确识别为真实样本的数量，FP（False Positive）表示将真实样本错误判定为伪造样本的数量，FN（False Negative）表示将伪造样本错误判定为真实样本的数量。Accuracy 能够直观反映模型在整体分类任务中的表现。

其次，AUC（Area Under the ROC Curve）表示 ROC 曲线（Receiver Operating Characteristic Curve）下的面积。ROC 曲线以 假正率（False Positive Rate, FPR）为横轴，以 真正率（True Positive Rate, TPR）为纵轴，通过改变分类阈值绘制而成。AUC 的取值范围为[0,1]，数值越大表示模型区分真实样本和伪造样本的能力越强。当 AUC 接近 1 时，说明模型具有较好的判别能力；当 AUC 接近 0.5 时，则表示模型的分类效果接近随机猜测。相比单一阈值下的准确率，AUC 能够更全面地反映模型在不同阈值条件下的性能。

最后，平均精度均值（mean Average Precision, mAP）是综合评价模型精确率与召回率的重要指标。首先计算不同召回率水平下的精确率（Precision），从而得到 Precision-Recall

曲线（PR 曲线）。随后对该曲线进行积分得到 平均精度（Average Precision, AP），而 mAP 则表示所有类别 AP 的平均值。mAP 能够综合反映模型在不同阈值条件下的检测能力，其数值越高表示模型的整体检测性能越好。在深度伪造检测与多模态识别任务中，mAP 常用于评价模型在不同样本分布条件下的稳定性与综合性能。

因此，在本文实验中同时采用 Accuracy、AUC 和 mAP 三种评价指标，以从整体分类性能、判别能力以及精确率—召回率关系等多个方面对模型进行全面评估。

5.3.2 FakeAVCeleb 数据集上的性能表现

FakeAVCeleb 是当前最具代表性的音视频深度伪造数据集之一，包含 500 个真实名人视频和 19500 个伪造视频，涵盖 FaceSwap、Face2Face、FaceShifter、NeuralTextures 等多种主流深度伪造方法。该数据集同时提供真实语音与伪造语音，使其成为评估音视频联合检测模型的重要基准数据集。



图 5-4 Fakeavceleb 数据集组成展示

如图 5-4 所示，FakeAVCeleb 将样本划分为四种不同的模态组合。首先，Real Audio & Real Video(A_R, V_R)表示真实音频与真实视频的组，该类样本完全未被篡改，通常作为检测模型的负样本。其次，Fake Audio & Real Video(A_F, V_R)表示伪造音频与真实视频的组，用于模拟语音深度伪造攻击，例如通过 voice cloning 或 neural speech synthesis 技术生成伪造语音，在保持视频真实的情况下替换说话人的声音。第三类为 Real Audio & Fake Video(A_R, V_F)，即真实音频与伪造视频的组，这种情形对应视觉层面的 deepfake 操作，如 face swapping 或 face reenactment，其中视频内容被篡改而音频保持真实。最后，Fake Audio & Fake Video(A_F, V_F)表示音频与视频均为伪造的样本，即完全的多模态深度伪造场景，也是检测难度最高的一类情况。

在实验中，本文遵循已有研究中的标准协议，将数据集按 70% 用于训练、30% 用于测试进行划分，并与多种代表性方法进行对比，包括视觉检测方法（MesoNet、Xception、LipForensics）以及多模态检测方法（AVN-J、VFD、AVoID-DF、AVFF）。

Method	Modality	AUC	Acc
MesoNet	V	60.9	57.3
Capsule	V	70.9	68.8
Xception	V	70.5	67.9
LipForensics	V	82.4	80.2
Multiple-Attention	V	79.3	77.6
SLAADD[1] [56] [1] [57] [1] [58]	V	72.1	70.5
AVN-J [57]	A-V	77.6	73.2
Emotion Don't Lie	A-V	79.8	78.1
AVFakeNet [58]	A-V	83.4	78.4
VFD	A-V	86.1	81.5
AVoiD-DF	A-V	89.2	83.7
AVFF	A-V	99.1	98.6
AV-LMMDetect (Ours)	A-V	99.2	98.02

表 5-1 Faleavceleb 数据集测试结果

实验结果如表 5-1 所示。可以观察到，传统视觉检测方法整体性能较低，例如 MesoNet 的 AUC 仅为 60.9%，准确率为 57.3%，Xception 的 AUC 为 70.5%。相比之下，基于音视频联合建模的方法整体性能明显更高，例如 VFD 和 AVoiD-DF 的 AUC 分别达到 86.1% 和 89.2%，表明跨模态信息对于深度伪造检测具有重要价值。本文提出的 AV-LMMDetect 在该数据集上取得 99.2% 的 AUC 和 98.02% 的准确率，与当前最先进方法 AVFF（AUC 99.1%，Acc 98.6%）相比性能相当，并在 AUC 指标上略有提升。

从整体趋势来看，实验结果体现出三个方面的重要结论。首先，多模态检测方法明显优于单模态视觉检测方法。例如，与当前性能最优的视觉方法 LipForensics 相比，AV-LMMDetect 在 AUC 上提升约 16.8 个百分点，说明音频信息能够有效补充视觉检测中的缺失信息，提高伪造检测的可靠性。其次，AV-LMMDetect 在性能上达到了当前 state-of-the-art（SOTA）水平，与 AVFF 等先进多模态方法基本持平，证明基于大规模多模态模型的检测框架具有较强的竞争力。最后，与传统多模态模型依赖浅层特征融合不同，大模型能够利用其强大的语义建模能力进行更深层的跨模态推理，从而在复杂伪造场景中获得更稳定的检测性能。

5.3.3 MAVOS-DD 多语言跨场景评估

为了进一步评估模型的跨语言泛化能力以及在开放环境下的检测性能，本文在 MAVOS-DD 数据集上进行了实验。MAVOS-DD 是一个大规模多语言音视频深度伪造数据集，包含 8 种语言（英语、中文、西班牙语、法语、德语、意大利语、葡萄牙语和俄语），总计超过 250 小时的视频数据，并覆盖 7 种不同的深度伪造方法。该数据集通过精心设计的数据划分，构建了多种具有挑战性的评估场景，以模拟真实应用中的开放环境。

具体而言，训练集与 In-domain 测试集中的真实样本与伪造样本均来自相同的数据分布，包含六种语言和四种生成模型，用于评估模型在已知条件下的检测性能。在此基础上，数据集进一步构建了三种开放集测试设置。Open-set model 在 In-domain 测试集的基础上，引入由未在训练阶段出现过的生成模型（如 Sonic、HifiFace 和 Roop）生成的伪造样本，用于评估模型对未知伪造方法的泛化能力；Open-set language 则在测试集中加入训练阶段未出现的语言（如德语和印地语），以评估模型的跨语言泛化能力；而 Open-set full 同时包含未见语言与未见生成模型生成的伪造样本，是最具挑战性的评估场景，用于全面测试模型在真实开放环境中的鲁棒性和泛化能力。

如图 5-5 所示，每一种数据分布右侧均展示了一个对应的伪造样本示例，以直观说明不同评估场景下的数据组成。




图 5-5 Mavos-DD 数据集展示

实验结果如表 5-2 所示。可以观察到，AV-LMMDetect 在多个评估场景下均取得了领先性能。在 In-domain 场景下，AV-LMMDetect 的 mAP 达到 0.97，AUC 为 0.97，准确率达到 92.92%，超过 AVFF（mAP 0.95）等现有方法，表明在充分训练数据条件下，大模型能够学习到更全面的音视频伪造特征。在 Open-set model 场景中，AV-LMMDetect 的 mAP 达到 0.98，AUC 为 0.94，准确率为 87.91%，显著优于 AVFF 的 mAP 0.85，说明模型在面对未见伪造方法时仍能够保持较强的检测能力，这主要得益于大模型较强的泛化能力和跨模态语义理解能力。

Method	Fine-tuned	In-domain			Open-set model			Open-set language			Open-set full		
		mAP	AUC	Acc	mAP	AUC	Acc	mAP	AUC	Acc	mAP	AUC	Acc
AVFF	×	0.51	0.51	52.45	0.5	0.5	22.58	0.51	0.51	59.46	0.5	0.5	35.34
MRDF	×	0.5	0.46	44.04	0.52	0.52	58.04	0.46	0.41	39.35	0.51	0.49	50.78
TALL	×	0.49	0.48	50.74	0.5	0.51	39.22	0.48	0.47	50.78	0.5	0.49	44.63
Qwen 2.5 Omni	×	0.47	0.44	49.25	0.77	0.45	20.84	0.38	0.43	55.5	0.61	0.41	32.26
AVFF	✓	0.95	0.95	86.93	0.85	0.89	75.34	0.9	0.9	84.26	0.87	0.89	77.68
MRDF	✓	0.9	0.9	84.27	0.78	0.88	78.32	0.88	0.88	82.15	0.82	0.86	78.87
TALL	✓	0.87	0.86	78.07	0.79	0.84	66.2	0.8	0.8	73.25	0.77	0.79	67.42
AV-LLMDETECT (Ours)	✓	0.97	0.97	92.92	0.98	0.94	87.91	0.88	0.9	85.58	0.96	0.92	85.09

表 5-2 Mavos-DD 数据集测试结果

在 Open-set language 场景下，AV-LMMDetect 的 mAP 为 0.88，AUC 为 0.90，准确率为 85.58%。虽然在 mAP 指标上略低于 AVFF，但在 AUC 和准确率方面仍保持领先。进一步分析表明，这一现象可能与部分低资源语言样本数量较少有关，例如俄语和葡萄牙语数据分布相对稀疏，从而对模型跨语言泛化能力产生一定影响。

在最具挑战性的 Open-set full 场景下，即同时面对未见语言和未见伪造方法时，各类方法的检测性能均出现明显下降。然而，AV-LMMDetect 仍取得 mAP 0.96、AUC 0.92、准确率 85.09% 的结果，显著优于 MRDF、TALL 等方法，并保持整体最优性能。这表明基于大规模多模态模型的检测框架在复杂开放环境中具有更强的鲁棒性和泛化能力。

综合 FakeAVCeleb 与 MAVOS-DD 的实验结果可以看出，AV-LMMDetect 在标准伪造检测场景与开放集跨语言场景中均表现出优异性能。得益于大模型在跨模态表示学习与语义推理方面的优势，该方法不仅能够实现高精度检测，还能够在未知伪造方法和多语言环境中保持较好的泛化能力，为真实世界中的深度伪造检测应用提供了有效解决方案。

5.3.4 消融实验

为了进一步验证所提出两阶段监督微调策略的有效性，本文在 MAVOS-DD 数据集的 Open-set full 场景下进行了消融实验。该场景同时包含训练阶段未见语言和未见的伪造方法，是最具挑战性的评估设置之一，因此能够更全面地反映模型在开放环境中的泛化能力。实验对比了四种不同训练配置，包括：（1）Zero-shot：不进行任何微调，直接使用预训练模型进行推理；（2）Stage 1 only：仅进行第一阶段 LoRA 微调；（3）Stage 2 only：直接进行编码器全参数微调；（4）Stage 1 + Stage 2：完整的两阶段训练策略。

Training Strategy	mAP	AUC	Acc (%)
Zero-shot	0.61	0.41	32.26
Stage 1 only	0.82	0.66	73.4
Stage 2 only	0.86	0.83	80.61
Stage 1 + Stage 2 (Ours)	0.96	0.92	85.09

表 5-3 两阶段训练策略消融实验结果（MAVOS-DD Open-set full）

实验结果如表 5-3 所示。从结果可以看出，未经微调的 Zero-shot 模型在该任务上的性能较低，准确率仅为 32.26%，AUC 为 0.41，说明预训练多模态模型虽然具备通用理解能力，但在深度伪造检测任务上仍然缺乏针对性。仅采用 Stage 1 LoRA 微调后，模型性能得到显著提升，准确率提升至 73.40%，AUC 达到 0.66，表明通过少量参数更新即可有效完成任务适配。相比之下，直接进行 Stage 2 编码器全参数微调的性能略高于 Stage 1，准确率达到 80.61%，AUC 为 0.83，说明对视觉与音频编码器进行联合优化能够提升模型对伪造特征的感知能力。

然而，最佳性能出现在两阶段联合训练（Stage 1 + Stage 2）的情况下。该策略在 Open-set full 场景下取得 mAP 0.96、AUC 0.92、准确率 85.09% 的结果，明显优于单阶段训练方案。这表明两阶段训练策略能够有效结合参数高效任务适配与跨模态特征学习的优势：第一阶段通过 LoRA 微调使模型快速对齐伪造检测任务，而第二阶段则通过解冻视觉与音频编码器进一步优化多模态特征表示，从而提高模型对复杂伪造模式的识别能力。

总体来看，消融实验结果充分验证了两阶段监督微调策略的有效性。相比于单阶段训练方案，该策略不仅能够提升模型整体性能，还能够在开放集场景下保持更稳定的检测能力，为基于大规模多模态模型的深度伪造检测提供了一种高效且可扩展的训练范式。

5.3.5 跨语言与跨模型泛化性分析

为了进一步评估 AV-LMMDetect 在复杂开放环境中的泛化能力，本文结合 MAVOS-DD 数据集中的多语言与开放集评估设置，对模型的跨语言和跨伪造方法性能进行了深入分析。MAVOS-DD 是一个多语言音视频深度伪造数据集，包含 8 种语言和超过 250 小时视频数据，同时覆盖 7 种不同的深度伪造方法，能够有效模拟真实应用场景中多语言、多生成模型并存的情况。该数据集通过 In-domain、Open-set model、Open-set language 和 Open-set full 四种评估设置，对模型的跨场景泛化能力进行系统测试。

首先，在跨语言泛化能力方面，MAVOS-DD 的 Open-set language 场景要求模型在测试阶段面对训练过程中未出现的语言。实验结果表明，AV-LMMDetect 在该场景下取得 mAP 0.88、AUC 0.90、Acc 85.58% 的性能，整体表现稳定，与 In-domain 场景相比仅出现有限性能下降。相比之下，部分传统多模态检测方法在跨语言场景中性能下降更加明显，例如 TALL 的准确率下降至 73.25%。这一结果说明，大规模多模态模型能够利用其在预训练阶段学习到的跨语言语音和视觉表示，在面对新的语言环境时仍能够保持较强的检测能力。同时，由于不同语言在数据规模和语音特征分布上存在差异，模型在部分低资源语言上的表现仍存在一定波动，这也说明跨语言深度伪造检测仍具有进一步研究空间。

其次，在跨伪造方法泛化能力方面，MAVOS-DD 的 Open-set model 场景用于评估模型在面对未知伪造方法时的检测能力。在该设置下，测试集包含训练阶段未见过的深度伪生成模型。实验结果表明，AV-LMMDetect 在该场景下取得 mAP 0.98、AUC 0.94、Acc 87.91% 的性能，明显优于 AVFF (mAP 0.85) 以及 MRDF 等方法。这表明，AV-LMMDetect 不仅能够识别特定生成方法产生的伪影特征，还能够学习到更加通用的跨模态伪造模式，例如音频与口型之间的时序不一致、生成视频中的纹理异常以及跨模态语义冲突等特征，从而在面对未知伪造方法时仍然保持较高检测准确率。

此外，在最具挑战性的 Open-set full 场景中，测试数据同时包含未见语言和未见伪造方法，能够综合评估模型的开放环境泛化能力。实验结果显示，AV-LMMDetect 仍取得 mAP 0.96、AUC 0.92、Acc 85.09% 的结果，在所有对比方法中保持最佳性能。这一结果表明，基于大规模多模态模型的检测框架能够在复杂开放场景中保持较强的鲁棒性，其泛化能力优于传统多模态融合模型。

结合 FakeAVCeleb 数据集上的实验结果可以进一步观察到，AV-LMMDetect 在标准数据集上同样表现出稳定性能。在 FakeAVCeleb 测试集上，模型取得 99.2% 的 AUC 和 98.02% 的准确率，达到当前最先进水平。综合两类数据集的实验结果可以看出，AV-LMMDetect 不仅能够在标准伪造检测任务中取得高精度结果，同时在跨语言和跨生成模型的开放场景下也具备较强的泛化能力。这一优势主要得益于大规模多模态模型在预训练阶段学

习到的丰富跨模态表示能力，以及两阶段监督微调策略对任务特征的有效适配，从而使模型能够捕捉更加通用的伪造模式，而不仅仅依赖特定数据集或生成方法中的局部特征。

5.4 本章小结

本章提出了基于大型多模态模型的音视频伪造检测方法 AV-LMMDetect。该方法以 Qwen 2.5 Omni 为基础,通过设计音视频联合编码方案、结构化提示工程和 Top-2 Token 预测策略,将大模型适配到伪造检测任务。采用两阶段监督微调策略,先通过 LoRA 高效适配高层推理,再解冻编码器学习底层伪造特征。实验表明,AV-LMMDetect 在 FakeAVCeleb 数据集上达到 99.2%的 AUC,在多语言 MAVOS-DD 数据集的四种开放集场景下均取得最优或次优性能,特别是在面对未见伪造方法时展现出强大的泛化能力。本章的研究展示了大型多模态模型在伪造检测领域的巨大潜力,为未来研究指明了方向。

第六章 面向语音安全的双因素级联验证系统设计与实现

6.1 引言

前述章节介绍的算法研究均基于软件层面,虽然能够有效检测深度伪造和识别匿名语音,但在实际应用中仍存在局限性。软件算法容易被绕过、处理流程缺乏物理隔离、难以提供端到端的安全保障。随着智能语音技术在日常生活中的广泛应用,如智能语音助手、语音支付、智能门锁、车载系统等场景,对语音安全的要求日益提高。[1] [62]

当前的语音安全方案主要面临以下问题:

- (1) 缺乏标准化硬件实现: 现有方法多为软件算法,运行在操作系统或云端,难以直接嵌入智能硬件。
- (2) 算法可绕过性: 软件层面的保护可能被恶意程序绕过,无法保证从语音采集到输出的完整安全链路。[1] [64]
- (3) 单一功能局限: 现有系统要么只进行说话人认证(ASV),要么只进行伪造检测(ADD),缺乏综合防护能力。
- (4) 边缘设备部署困难: 资源受限的边缘设备难以运行复杂的深度学习模型,需要硬件加速支持。[1] [68]

为解决上述问题,本章提出了一种集说话人认证(Automatic Speaker Verification, ASV)与音频深度伪造检测(Audio Deepfake Detection, ADD)于一体的级联式语音隐私保护硬件装置。该装置通过物理封装将语音安全处理集成于语音采集前端,在语音输入阶段即完成身份验证与真伪判别,构建双因素语音验证机制,为智能语音应用提供物理级安全防护。

6.2 ASV+ADD 级联系统架构

ASV+ADD 级联架构的核心思想是将"身份认证"与"真伪检测"两个维度相结合,形成双因素验证机制。只有同时通过身份验证(确认是授权用户)和真伪检测(确认是真实人声),语音信号才被允许输出,否则被拒绝或标记。表 6-1 总结了 ASV+ADD 级联结构的必要性和优势:

组件	功能	安全价值
ASV 模块	自动识别说话人身份	判断"是谁在说",防止未授权用户访问
ADD 模块	检测语音是否被伪造	判断"是否为真实人声",防止语音合成攻击

两者级联	仅当身份匹配且语音真实时 允许通过	构建“双因素语音验证”,大幅提升抗伪造能力
------	----------------------	-----------------------

表 6-1 ASV+ADD 级联系统的安全价值

系统整体架构如下:麦克风 → ASV 模块 (身份认证) → ADD 模块 (真伪检测) → 控制单元 (联合决策) → 音频输出

6.2.1 自动说话人认证(ASV)模块:身份确认

ASV 模块负责识别说话人身份,判断当前语音是否来自授权用户。该模块包含以下子模块:

- (1) **语音输入通道**:系统通过麦克风采集环境中的语音信号,并将模拟音频转换为数字信号进行后续处理。为实现高保真、低延迟的数据传输,采用 I2S (Inter-IC Sound) 接口进行数字音频通信,配置参数包括:采样率 16 kHz (适用于语音处理场景)、位深度 16 bit,以及支持单声道或立体声模式,从而满足不同应用场景下的音频采集需求。
- (2) **特征提取模块**:在特征提取模块中,将时域语音信号转换为频域表示。首先对语音进行分帧处理,采用 25 ms 帧长、10 ms 帧移,并加汉明窗以减小频谱泄漏;随后对每帧信号进行 512 点快速傅里叶变换 (FFT),得到频谱表示;在此基础上通过梅尔滤波器组进行频率映射,设置 80 个梅尔频率通道,覆盖 20–8000 Hz 的语音有效频段。最终输出梅尔频谱图 $M \in R^{80 \times T}$,其中 T 表示时间帧数,用于后续模型输入[1] [70]。
- (3) **嵌入模型模块**:本研究采用 ECAPA-TDNN 神经网络将 80 维梅尔频谱特征映射为固定长度的说话人嵌入向量。考虑到嵌入式硬件资源受限的问题,本文选用轻量化结构设计:网络整体结构为 $\text{Conv1D}(512) \rightarrow \text{SE-Res2Block} \times 2 \rightarrow \text{Conv1D}(1536) \rightarrow \text{Attentive Statistical Pooling}$ [1] [70],通过注意力统计池化将帧级特征聚合为话语级表示,最终输出 192 维说话人嵌入向量 $v \in R^{192}$ 。该轻量化模型参数规模约为 6M,相比标准版本减少约 60%,在嵌入式平台 ESP32-S3 上的推理时间低于 50ms,兼顾识别性能与实时性要求。
- (4) **相似度匹配模块**:在身份认证阶段,系统将当前提取的说话人嵌入向量与预先注册的声纹模板进行比对。系统支持存储多个授权用户的声纹模板 (通常为 5–20 个),以满足多用户场景需求。相似度计算采用余弦相似度度量[1] [71]

$$\text{sim}(v, v_i) = \frac{v \cdot v_i}{\|v\| \|v_i\|} \quad (6-1)$$

分别计算当前嵌入向量与所有模板之间的相似度,并取最大值作为最终匹配分数

$$\text{score} = \max_i \text{sim}(v, v_i) \quad (6-2)$$

在判决阶段，若该分数大于或等于预设阈值 θ_{ASV} （例如 0.7），则判定为授权用户；否则执行拒识处理，从而实现基于嵌入相似度的身份验证机制。

(5) **ASV 输出模块**:系统的身份识别输出结果包括三部分：首先给出匹配的身份 ID，例如 User_001 等用户标识；其次输出对应的置信度，即基于嵌入相似度计算得到的分数 $score \in [0,1]$ ，用于量化当前语音与注册模板之间的匹配程度；最后根据预设判决阈值给出最终决策结果，即 Accept（接受）或 Reject（拒绝），从而完成完整的身份认证流程[1] [72]。

6.2.2 音频深度伪造检测(ADD)模块:真伪判别

ADD 模块负责判断语音是否为真实人声还是合成伪造。该模块与 ASV 模块并行处理,共享语音输入。[1] [75]

- (1) **声学特征提取器**:在音频伪造检测特征构建过程中，采用多维声学特征联合建模策略。首先提取线性频率倒谱系数（LFCC），相较于 MFCC，其对频谱异常更为敏感，能够更有效捕捉伪造语音中的高频结构失真；其次提取 STFT 的相位谱信息，由于相位特征较被生成模型精确建模，伪造语音中常出现不自然的相位跳变现象；同时计算短时能量包络，分析能量随时间变化规律，合成语音通常呈现更均匀的能量分布模式。最后将上述特征进行拼接，构建联合特征表示 $[Mel; LFCC; Phase; Energy] \in R^{160 \times T}$ ，为后续模型提供更加丰富且互补的判别信息。
- (2) **频谱与相位图分析**:为了捕捉音频信号在时频域中的伪造模式，本文对梅尔频谱图和相位图进行二维卷积分析。相关研究表明，基于时频表示的卷积神经网络能够有效学习伪造语音中的局部谱纹理和全局异常模式[1] [77]。具体而言，将提取的时频特征图视为二维图像输入到轻量化卷积神经网络（CNN）中进行特征建模。该网络由多层卷积与池化结构组成，首先通过两层 Conv2D(32) 提取低层特征，随后经过 MaxPool 进行下采样；接着通过两层 Conv2D(64) 进一步学习中层语义特征，并再次进行 MaxPool；随后使用两层 Conv2D(128) 提取更高层的判别性特征。最后，通过 Global Average Pooling 对特征图进行全局聚合，得到一个 128 维特征向量 $f \in R^{128}$ ，作为后续多模态融合与分类模块的输入。
- (3) **伪造检测子网**:在分类阶段，将提取到的特征向量输入全连接分类器进行二分类判别。网络结构依次为：FC(128) $\rightarrow$ ReLU $\rightarrow$ Dropout(0.3) $\rightarrow$ FC(64) $\rightarrow$ ReLU $\rightarrow$ FC(2)，通过两层非线性映射与正则化机制增强特征表达能力并缓解过拟合。最终输出为二分类 logits 向量 $[z_{real}, z_{fake}]$ ，并通过 Softmax 函数将其转换为概率分布，其中

$$p(real) = \frac{\exp(z_{real})}{\exp(z_{real}) + \exp(z_{fake})}, \quad (6-3)$$

从而得到真实与伪造类别的预测概率。

- (4) 真伪判定输出:系统输出包括三部分内容: 首先给出真伪标签, 即 Real (真实) 或 Fake (伪造); 其次输出对应的伪造置信度 $p(fake) \in [0,1]$, 用于量化模型对当前样本为伪造语音的判断概率; 最后根据预设阈值 θ_{ADD} (例如 0.5) 进行决策, 当 $p(fake) \geq \theta_{ADD}$ 时判定为伪造, 否则判定为真实, 从而实现基于概率阈值的自动化判别机制。

6.2.3 双因素验证逻辑与控制单元

控制单元接收 ASV 和 ADD 两个模块的输出,进行联合决策。决策逻辑如表 6-2 所示:

ASV 结果	ADD 结果	最终决策	说明
Accept	Real	Allow	身份匹配且为真实语音,允许输出
Accept	Fake	Deny	身份匹配但语音伪造,拒绝(合成攻击)
Reject	Real	Deny	身份不匹配,拒绝(未授权用户)
Reject	Fake	Deny	身份不匹配且伪造,拒绝(复合攻击)

表 6-2 ASV+ADD 联合决策逻辑

系统的联合决策逻辑可表示为:

$$Decision = \begin{cases} Allow, & \text{if } (ASV = Accept) \wedge (ADD = Real) \\ Deny, & \text{otherwise} \end{cases} \quad (6-4)$$

即仅当说话人认证 (ASV) 判定为 Accept 且音频伪造检测 (ADD) 判定为 Real 时, 系统才允许通过, 否则执行拒绝操作。

控制单元基于 STM32F4 或 STM32F7 系列微控制器实现, 主要负责协调 ASV 与 ADD 两个模块的并行执行流程, 实施联合决策逻辑, 并通过模拟开关或数字 I/O 控制音频输出通路。同时, 系统支持日志记录功能, 包括时间戳、决策结果及用户 ID 等信息; 在扩展场景下, 还可通过蓝牙或 Wi-Fi 将决策结果上传至上位机或后台管理系统, 实现远程监控与数据管理。

6.3 硬件实现与集成方案

6.3.1 信号流处理与 I2S 接口设计

装置的信号处理流程如下:

- (1) 语音采集: 数字 MEMS 麦克风(如 SPH0645LM4H)通过 I2S 接口连接至主控芯片,直接输出数字音频流,无需额外 ADC。
- (2) 预处理: 对原始 PCM 数据进行预加重滤波和分帧处理。
- (3) 特征提取: 在主控芯片(ESP32-S3 或 STM32F7)上运行 STFT 和梅尔滤波,计算梅尔频谱。利

用硬件加速器(如 ESP32-S3 的 AI 指令集)加速 FFT 运算。

(4) 模型推理: ASV 和 ADD 模型以量化方式(INT8)部署,利用嵌入式深度学习框架(如 TensorFlow Lite Micro, TinyML)进行推理。

(5) 决策与输出: 控制单元根据决策结果,控制音频通路的模拟开关(如 TS5A3159)或数字 MUX,决定是否将音频信号传递到输出端口。

在 I2S 接口配置方面,系统采用 1.024 MHz 的时钟频率(对应 16 kHz 采样率 $\times$ 16 bit 位宽 $\times$ 双通道数据传输),主从模式下由主控芯片作为 I2S Master 提供时钟信号,确保数据同步与稳定传输。同时,为降低 CPU 负载并提高数据吞吐效率,采用 DMA(Direct Memory Access, 直接内存访问)机制进行音频数据缓冲与传输,从而实现高效、实时的音频采集处理。

6.3.2 嵌入式芯片选型与物理封装

(1) 芯片选型方案一:ESP32-S3(如图 6-1 所示)

该平台具备较高的性价比优势,集成 Wi-Fi 与 BLE 无线通信模块,搭载主频 240 MHz 的双核 Xtensa LX7 处理器,并支持 AI 加速指令,在保证一定计算能力的同时成本低于 3 美元,适合大规模部署。在存储方面,片上集成 512 KB SRAM,并支持外扩 PSRAM 至 8 MB;Flash 容量通常为 4–16 MB,可满足嵌入式推理与模型存储需求。凭借低成本与无线通信集成优势,该方案适用于成本敏感的消费级产品场景,如智能音箱、智能门铃等终端设备。




图 6-1 ESP32-S3 芯片示意

(2) 芯片选型方案二:STM32F7 系列(如图 6-2 所示)

该平台具备较强的工业级性能与稳定性，搭载主频 216 MHz 的 Cortex-M7 处理器，支持硬件浮点单元（FPU）与 DSP 指令扩展，能够高效完成信号处理与嵌入式推理任务，同时具备较高的系统可靠性与环境适应能力。在存储方面，片上集成 512 KB SRAM，Flash 容量为 1–2 MB，适合部署中小规模模型与实时控制逻辑。凭借其稳定性与安全性优势，该方案更适用于工业级应用场景，如车载系统与金融支付终端等对可靠性要求较高的领域。




图 6-2 STM32F7 芯片示意

物理封装设计:装置采用模块化设计,封装在一个小型盒体内(约 5cm×5cm×2cm):系统整体采用分层式结构设计:第一层为麦克风阵列模块,可选配 2–4 个麦克风,支持波束成形与降噪处理,以提升语音采集质量;第二层为主控 PCB 板,集成主控芯片、电源管理电路、I2S 音频接口及模拟开关等核心组件,实现数据处理与控制功能;第三层为供电模块,支持 USB 外接供电或锂电池供电,满足不同应用场景的电源需求。外壳采用阻燃 ABS 塑料材质,并配备状态指示 LED 灯(绿色表示 Allow,红色表示 Deny),以直观反馈系统验证结果。

6.4 应用场景

ASV+ADD 级联装置可广泛应用于多种智能语音场景。在智能语音助手中,可嵌入智能音箱或手机终端,防止未授权用户操控设备或利用合成语音发起指令攻击;在语音支付终端(如银行 ATM、POS 机)中,可确保支付指令来源于真实授权用户,降低语音合成欺诈风险;在智能门锁系统中,可作为声纹解锁的双因素验证机制,有效抵御录音重放与合成语音攻击;在车载语音控制系统中,可防止后排乘客冒充驾驶员发出危险指令;在远程会议场景中,可嵌入会议麦克风设备,实时检测与会者身份与语音真伪,降低深度伪造冒充风险。

系统测试结果表明,该装置在性能与实时性方面均满足实际应用需求:ASV 模块在 LibriSpeech 测试集上的等错误率(EER)为 3.8%,轻量化后性能下降不足 1%;ADD 模块在 ASVspoof 2019 LA 数据集上的 AUC 达到 92.3%;联合决策机制实现攻击拒绝率 98.5%,误

拒率低于 2%。在嵌入式平台 ESP32-S3 上,端到端处理延迟小于 100 ms,满足实时交互需求;功耗方面,待机功耗低于 5 mW,工作功耗低于 500 mW,适合电池供电场景部署。

6.5 本章小结

本章设计并实现了一种集说话人认证(ASV)与音频深度伪造检测(ADD)于一体的级联式语音隐私保护硬件装置。该装置通过将 ASV 和 ADD 模块以级联结构集成于物理设备中,在语音采集阶段即完成身份验证与真伪判别,构建了双因素语音验证机制。系统采用轻量化的 ECAPA-TDNN 和 CNN 模型,在 ESP32-S3 或 STM32F7 等嵌入式平台上实现实时推理。实验表明,装置在保持高检测性能的同时,实现了低延迟(<100ms)和低功耗(<500mW)。该装置可广泛应用于智能语音助手、语音支付、智能门锁、车载系统等场景,为语音安全提供了硬件级防护方案。相关技术已形成发明专利申请。本章的研究展示了从算法到硬件的完整转化路径,为语音隐私保护技术的产业化应用提供了重要参考。

第七章 总结与展望

7.1 全文工作总结

本文围绕多媒体内容安全与隐私保护问题，系统研究了语音匿名化安全评测、视频深度伪造检测、多模态音视频联合检测以及语音安全硬件系统实现等关键技术，形成了从安全评估、检测算法到系统部署的完整研究框架。具体工作总结如下。

(1) 面向语音匿名化系统的安全评测方法研究。

针对现有语音匿名化系统在深层表示空间中安全评估不足的问题，本文提出了一种基于频谱增强与自监督表示学习的匿名语音攻击方法 SpecWav-Attack。该方法通过频谱特征调整结合 Wav2Vec 2.0 表征学习，并采用两阶段增量训练策略构建说话人识别攻击模型，实现对匿名语音中残留身份信息的有效恢复。实验结果表明，该方法可将说话人识别攻击的等错误率（EER）降低至 17.34%，相比基线方法提升 30.3%。研究进一步揭示了当前匿名化技术在隐私保护方面的潜在漏洞，尤其在性别用户之间存在隐私保护能力不均衡的问题，为未来匿名化方法的安全评估与改进提供了重要依据。本研究为后续多模态安全研究奠定了音频单模态安全评测基础。

(2) 基于动态特征选择机制的视频伪造检测方法研究。

在语音安全评测研究基础上，本文将研究范围拓展至视觉模态，针对视频深度伪造检测中跨数据集泛化能力不足的问题，提出了一种生物启发式的选择性特征表达网络 SFE-Net。该方法借鉴差异基因表达机制，通过构建多分支特征提取结构与选择性激活模块，实现对不同伪造线索的自适应特征表达。网络集成了五类互补视觉特征提取器，包括光照一致性特征、高频信息特征、压缩重建特征、形态学操作特征以及纹理特征，并通过动态选择机制实现多特征联合判别。在 FaceForensics++ 等多个数据集上的跨数据集实验结果表明，该方法的平均 AUC 达到 91.9%，显著优于传统固定特征检测方法。该研究展示了生物启发式机制在神经网络架构设计中的潜在优势，为视频伪造检测模型的泛化能力提升提供了新的思路。

(3) 基于多模态大模型的音视频联合伪造检测方法研究。

在单模态语音与视觉检测研究基础上，本文进一步面向复杂的音视频联合伪造场景，提出了一种基于多模态大模型的检测框架 AV-LMMDetect。该方法以 Qwen2.5-Omni 多模态大模型为基础，通过构建音视频联合编码机制，实现音频与视觉特征在语义层与时序层的深度融合。同时设计了两阶段监督微调策略，使模型能够适应深度伪造检测任

务。在 FakeAVCeleb 数据集上,该方法取得 99.2% AUC 的检测性能;在多语言 MAVOS-DD 数据集的开放集评测环境下,模型在未知伪造方法与跨语言场景中仍表现出良好的泛化能力。研究结果表明,多模态大模型在复杂伪造检测任务中具有显著优势,为未来多模态安全检测研究提供了新的技术路径。

(4) 面向语音安全的双因素级联验证系统设计与实现。

在算法模型研究基础上,本文进一步从系统工程角度出发,设计并实现了一种融合说话人认证(ASV)与音频伪造检测(ADD)的级联式语音安全装置。系统基于 ESP32-S3 / STM32F7 嵌入式平台构建,实现了语音采集、身份认证与音频真伪检测的一体化功能,通过双因素验证机制显著提升语音身份认证系统的安全性。实验结果表明,该系统能够在低功耗(<500mW)条件下实现实时推理(<100ms 延迟)。相关技术成果已形成发明专利申请,为语音安全技术的工程化部署与产业化应用提供了可行方案。

综上所述,本文的研究工作构建了一条完整的多媒体内容安全技术路线:从语音匿名化系统的安全评估(红队攻击分析)出发,逐步扩展至视频深度伪造检测(视觉模态)与音视频联合检测(多模态融合),最终实现软硬件协同的语音安全防护系统。该研究实现了从单模态安全评测到多模态统一检测、从算法模型创新到工程化系统实现的全面技术探索,为多媒体内容安全与隐私保护领域提供了系统性的理论方法与技术支撑。

本文的研究成果形成了从红队攻击测试到蓝队防御体系、从单模态检测到多模态融合、从理论算法到硬件实现的完整技术链条,为多媒体内容安全与隐私保护提供了系统性的技术支撑。

7.2 研究局限性分析

尽管本文取得了一系列研究成果,但仍存在以下局限性和不足:

- (1) 数据集局限性:训练数据主要来源于公开数据集(如 LibriSpeech、FaceForensics++),与真实复杂应用场景在数据分布、设备差异与环境噪声等方面仍存在差距,可能影响模型在实际部署中的泛化能力。其次,低资源语言(如俄语、葡萄牙语)相关数据相对不足,导致模型在跨语言场景下的适应能力有所下降。最后,现有训练过程中缺乏系统性的对抗性样本覆盖,使得模型在面对针对性构造的复杂扰动时鲁棒性仍有提升空间。这些问题为后续研究提供了进一步优化与拓展的方向。
- (2) 计算资源约束:AV-LMMDetect 依赖于规模约 70 亿参数的大型多模态模型,训练与部署成本较高,对计算资源和存储资源提出了较大要求;其次,为满足嵌入式场景需求,硬件装置中部署的是轻量化模型版本,其检测性能相较服务器端完整模型存在一定下降;此外,边缘设备的算力与功耗限制也对复杂模型的实时推理能力产生

影响，制约了高复杂度模型在终端侧的直接应用。这些问题为后续模型压缩与系统优化提供了重要研究方向。

- (3) 对抗攻击鲁棒性:尽管 SFE-Net 与 AV-LMMDetect 在公开基准数据集上取得了优异表现，但其在面对针对模型结构与梯度信息设计的白盒对抗攻击时的鲁棒性尚未得到充分验证，仍有进一步系统评估与强化的空间。此外，SpecWav 框架在语音匿名化安全评测中揭示的深层表示可分性问题，表明高维特征空间中的结构信息可能被模型充分利用，这一现象同样对伪造检测系统具有启示意义，即检测模型本身也可能面临被结构性扰动影响的风险。因此，有必要在后续研究中加强对检测系统安全边界与鲁棒性的综合分析。
- (4) 硬件成本考量:尽管 ASV+ADD 级联装置在设计过程中已进行成本优化，但相较于纯软件部署方案，仍需要额外的硬件投入与维护成本。同时，若实现规模化生产与市场推广，还需在工程可靠性、生产工艺及成本控制等方面进一步优化，以提升整体经济性与实际落地可行性。

7.3 未来研究方向

基于本文的研究成果与现有技术局限，未来工作可围绕模型鲁棒性提升、系统轻量化部署、隐私保护机制完善以及多模态智能化发展等方向进一步深入。

首先，在模型安全与鲁棒性方面，随着伪造技术不断演进，检测模型本身也可能面临更复杂的扰动挑战。未来可构建更加系统化的安全评测体系，研究不同场景下模型的稳定性与泛化能力，并探索对抗训练、鲁棒优化及协同优化机制，从而提升检测模型在复杂环境中的适应能力。同时，可借鉴博弈论思想构建动态攻防演化框架，使检测系统在不断变化的伪造策略下保持持续优化能力。

其次，在模型轻量化与边缘部署方面，随着检测系统向嵌入式设备与终端侧延伸，模型复杂度与计算资源之间的矛盾日益突出。未来可结合知识蒸馏、网络剪枝与量化压缩等技术，在保证性能的前提下降低模型规模；同时探索神经架构搜索（NAS）自动设计适配边缘设备的网络结构，并结合专用硬件加速方案提升推理效率，为实际应用场景提供可行的工程支撑。

再次，在隐私保护与分布式学习层面，可引入联邦学习框架，在不直接汇集原始数据的情况下提升模型泛化能力；结合差分隐私、安全多方计算等技术，在模型训练与推理阶段保护敏感信息安全；同时探索基于区块链的可信计算机制，提高检测结果的透明度与不可篡改性，为多媒体内容安全构建更加可信的基础设施。

在多模态大模型发展方向上，未来可进一步研究高效的跨模态融合机制，以降低多模态模型的计算成本；引入持续学习与元学习方法，使模型能够快速适应新型伪造技术；同时加

强可解释性研究，构建具备可视化分析与决策依据输出能力的检测系统，提高模型的透明度与可审计性。

最后，在标准化与产业化路径方面，有必要推动语音隐私保护与多媒体伪造检测相关技术规范的建立，加强学术界与产业界协同合作，构建开放测试平台与评测体系，促进技术成熟与规模化应用。同时，应持续关注伦理与法律问题，在保障技术创新的同时平衡隐私保护、信息安全与社会价值。

随着深度伪造技术不断演进以及智能语音应用场景的持续扩展，多媒体内容安全与隐私保护将面临更加复杂的挑战。本文的研究为构建音频到多模态的内容安全技术体系奠定了基础，未来仍需在算法创新、系统工程与治理机制层面协同推进，形成更加安全、可信与可持续发展的智能多媒体生态体系。

参考文献

- [1] Goodfellow, IJ, Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. *Advances in neural information processing systems*, 27.
- [2] Kingma, DP, & Welling, M. (2013). Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*.
- [3] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33, 6840-6851.
- [4] Van Den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., ... & Kavukcuoglu, K. (2016). Wavenet: A generative model for raw audio. *arXiv preprint arXiv:1609.03499*, 12(1).
- [5] Wang, Y., Skerry-Ryan, R. J., Stanton, D., Wu, Y., Weiss, R. J., Jaitly, N., ... & Saurous, R. A. (2017). Tacotron: Towards end-to-end speech synthesis. *arXiv preprint arXiv:1703.10135*.
- [6] Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in neural information processing systems*, 33, 12449-12460.
- [7] Thies, J., Zollhofer, M., Stamminger, M., Theobalt, C., & Nießner, M. (2016). Face2face: Real-time face capture and reenactment of rgb videos. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2387-2395).
- [8] Korshunov, P., & Marcel, S. (2018). Deepfakes: a new threat to face recognition? assessment and detection. *arXiv preprint arXiv:1812.08685*.
- [9] Tomashenko, N., Miao, X., Champion, P., Meyer, S., Wang, X., Vincent, E., ... & Todisco, M. (2024). The voiceprivacy 2024 challenge evaluation plan. *arXiv preprint arXiv:2404.02677*.
- [10] Tomashenko, N., Wang, X., Vincent, E., Patino, J., Srivastava, B. M. L., Noé, P. G., ... & Maouche, M. (2022). The voiceprivacy 2020 challenge: Results and findings. *Computer Speech & Language*, 74, 101362.
- [11] Hsu, WN, Bolte, B., Tsai, YHH, Lakhotia, K., Salakhutdinov, R., & Mohamed, A. (2021). Hubert: Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM transactions on audio, speech, and language processing*, 29, 3451-3460.
- [12] Korshunov, P., & Marcel, S. (2018). Deepfakes: a new threat to face recognition? assessment and detection. *arXiv preprint arXiv:1812.08685*.
- [13] Thies, J., Zollhöfer, M., & Nießner, M. (2019). Deferred neural rendering: Image synthesis using neural textures. *Acm Transactions on Graphics (TOG)*, 38 (4), 1-12.
- [14] Nguyen, H. H., Yamagishi, J., & Echizen, I. (2019, May). Capsule-forensics: Using capsule networks to detect forged images and videos. In *ICASSP 2019-2019 IEEE international conference on*

参考文献

- acoustics, speech and signal processing (ICASSP)* (pp. 2307-2311). IEEE.
- [15] Li, L., Bao, J., Zhang, T., Yang, H., Chen, D., Wen, F., & Guo, B. (2020). Face x-ray for more general face forgery detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 5001-5010).
- [16] Ni, Y., Meng, D., Yu, C., Quan, C., Ren, D., & Zhao, Y. (2022). Core: Consistent representation learning for face forgery detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 12-21).
- [17] Qian, Y., Yin, G., Sheng, L., Chen, Z., & Shao, J. (2020, August). Thinking in frequency: Face forgery detection by mining frequency-aware clues. In *European conference on computer vision* (pp. 86-103). Cham: Springer International Publishing.
- [18] Liu, H., Li, X., Zhou, W., Chen, Y., He, Y., Xue, H., ... & Yu, N. (2021). Spatial-phase shallow learning: rethinking face forgery detection in frequency domain. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 772-781).
- [19] Chollet, F. (2017). Xception: Deep learning with depthwise separable convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1251-1258).
- [20] Rossler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., & Nießner, M. (2019). Faceforensics++: Learning to detect manipulated facial images. In *Proceedings of the IEEE/CVF international conference on computer vision* (pp. 1-11).
- [21] Tan, M., & Le, Q. (2019, May). Efficientnet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning* (pp. 6105-6114). PMLR.
- [22] Haliassos, A., Vougioukas, K., Petridis, S., & Pantic, M. (2021). Lips don't lie: A generalisable and robust approach to face forgery detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 5039-5049).
- [23] Zhao, H., Zhou, W., Chen, D., Wei, T., Zhang, W., & Yu, N. (2021). Multi-attentional deepfake detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 2185-2194).
- [24] Oorloff, T., Koppiseti, S., Bonettini, N., Solanki, D., Colman, B., Yacoob, Y., ... & Bharaj, G. (2024). Avff: Audio-visual feature fusion for video deepfake detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 27102-27112).
- [25] Zou, H., Shen, M., Hu, Y., Chen, C., Chng, ES, & Rajan, D. (2024, April). Cross-modality and within-modality regularization for audio-visual deepfake detection. In *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 4900-4904). IEEE.
- [26] Xu, Y., Liang, J., Jia, G., Yang, Z., Zhang, Y., & He, R. (2023). Tall: Thumbnail layout for deepfake video detection. In *Proceedings of the IEEE/CVF international conference on computer vision* (pp.

参考文献

- 22658-22668).
- [27] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... & Sutskever, I. (2021, July). Learning transferable visual models from natural language supervision. In *International conference on machine learning* (pp. 8748-8763). PmLR.
- [28] Li, J., Li, D., Xiong, C., & Hoi, S. (2022, June). Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International conference on machine learning* (pp. 12888-12900). PMLR.
- [29] Xu, J., Guo, Z., Hu, H., Chu, Y., Wang, X., He, J., ... & Lin, J. (2025). Qwen3-omni technical report. *arXiv preprint arXiv:2509.17765* .
- [30] Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., ... & McGrew, B. (2023). Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.
- [31] Khalid, H., Tariq, S., Kim, M., & Woo, S. S. (2021). FakeAVCeleb: A novel audio-video multimodal deepfake dataset. *arXiv preprint arXiv:2108.05080*.
- [32] Croitoru, FA, Hondru, V., Popescu, M., Ionescu, RT, Khan, FS, & Shah, M. (2025). MAVOS-DD: Multilingual Audio-Video Open-Set Deepfake Detection Benchmark. *arXiv preprint arXiv:2505.11109* .
- [33] Desplanques, B., Thienpondt, J., & Demuynck, K. (2020). Ecapa-tdnn: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification. *arXiv preprint arXiv:2005.07143* .
- [34] Gao, S. H., Cheng, M. M., Zhao, K., Zhang, X. Y., Yang, M. H., & Torr, P. (2019). Res2net: A new multi-scale backbone architecture. *IEEE transactions on pattern analysis and machine intelligence*, 43(2), 652-662.
- [35] Grattafiori, A., Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., ... & Vasic, P. (2024). The llama 3 herd of models. *arXiv preprint arXiv:2407.21783* .
- [36] Wang, Y., Skerry-Ryan, RJ, Stanton, D., Wu, Y., Weiss, RJ, Jaitly, N., ... & Saurous, RA (2017). Tacotron: Towards end-to-end speech synthesis. *arXiv preprint arXiv:1703.10135* .
- [37] Ren, Y., Ruan, Y., Tan, X., Qin, T., Zhao, S., Zhao, Z., & Liu, TY (2019). FastSpeech: Fast, robust and controllable text to speech. *Advances in neural information processing systems* , 32 .
- [38] Kaneko, T., Kameoka, H., Tanaka, K., & Hojo, N. (2020). CycleGAN-vc3: Examining and improving cycleGAN-vcs for mel-spectrogram conversion. *arXiv preprint arXiv:2010.11672* .
- [39] Wu, DY, Chen, YH, & Lee, HY (2020). Vqvc+: One-shot voice conversion by vector quantization and u-net architecture. *arXiv preprint arXiv:2006.04154* .
- [40] Dehak, N., Kenny, P. J., Dehak, R., Dumouchel, P., & Ouellet, P. (2010). Front-end factor analysis for speaker verification. *IEEE Transactions on Audio, Speech, and Language Processing*, 19(4), 788-798.
- [41] Snyder, D., Garcia-Romero, D., Sell, G., Povey, D., & Khudanpur, S. (2018, April). X-vectors: Robust

参考文献

- dnn embeddings for speaker recognition. In *2018 IEEE international conference on acoustics, speech and signal processing (ICASSP)* (pp. 5329-5333). IEEE.
- [42] Panayotov, V., Chen, G., Povey, D., & Khudanpur, S. (2015, April). Librispeech: an asr corpus based on public domain audio books. In *2015 IEEE international conference on acoustics, speech and signal processing (ICASSP)* (pp. 5206-5210). IEEE.
- [43] Graves, A. (2012). Long short-term memory. *Supervised sequence labelling with recurrent neural networks*, 37-45.
- [44] Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. (2019). Celeb-df (v2): a new dataset for deepfake forensics [j]. *arXiv preprint arXiv* .
- [45] Dolhansky, B., Bitton, J., Pflaum, B., Lu, J., Howes, R., Wang, M., & Ferrer, C. C. (2020). The deepfake detection challenge (dfdc) dataset. *arXiv preprint arXiv:2006.07397*.
- [46] Dolhansky, B., Howes, R., Pflaum, B., Baram, N., & Ferrer, C. C. (2019). The deepfake detection challenge (dfdc) preview dataset. *arXiv preprint arXiv:1910.08854*.
- [47] Alayrac, JB, Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., ... & Simonyan, K. (2022). Flamingo: a visual language model for few-shot learning. *Advances in neural information processing systems* , 35 , 23716-23736.
- [48] Li, J., Li, D., Savarese, S., & Hoi, S. (2023, July). Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International conference on machine learning* (pp. 19730-19742). PMLR.
- [49] Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual instruction tuning. *Advances in neural information processing systems*, 36, 34892-34916.
- [50] Zhang, H., Li, X., & Bing, L. (2023, December). Video-llama: An instruction-tuned audio-visual language model for video understanding. In *Proceedings of the 2023 conference on empirical methods in natural language processing: system demonstrations* (pp. 543-553).
- [51] Maaz, M., Rasheed, H., Khan, S., & Khan, F. (2024, August). Video-chatgpt: Towards detailed video understanding via large vision and language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 12585-12602).
- [52] Girdhar, R., El-Nouby, A., Liu, Z., Singh, M., Alwala, K. V., Joulin, A., & Misra, I. (2023). Imagebind: One embedding space to bind them all. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 15180-15190).
- [53] Wang, P., Bai, S., Tan, S., Wang, S., Fan, Z., Bai, J., ... & Lin, J. (2024). Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution. *arXiv preprint arXiv:2409.12191* .
- [54] OpenAI, R. (2023). Gpt-4 technical report. arxiv 2303.08774. *View in Article* , 2 (5), 1.
- [55] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby,

参考文献

- N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929.
- [56] Liang Chen, Yong Zhang, Yibing Song, Lingqiao Liu, and Jue Wang, “Self-supervised learning of adversarial example: Towards good generalizations for deepfake detection,” in Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022, pp. 18710–18719.
- [57] Qian Y, Chen Z, Wang S. Audio-visual deep neural network for robust person verification[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 1079–1092.
- [58] Ilyas H, Javed A, Malik K M. AVFakeNet: A unified end-to-end dense Swin transformer deep learning model for audio-visual deepfakes detection[J]. Applied Soft Computing, 2023, 136: 110124.
- [59] Li, Y., Zheng, Y., Guo, Z., Wang, Y., Yin, J., & Fei, H. (2025, April). SpecWav-Attack: Leveraging spectrogram resizing and wav2vec 2.0 for attacking anonymized speech. In *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 1-2). IEEE.
- [60] Li, Y., Zheng, Y., Wang, Y., Yin, J., & Fei, H. (2025, April). SFE-net: Harnessing biological principles of differential gene expression for improved feature selection in deep learning networks. In *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 1-5). IEEE.
- [61] Cao, S., Li, Y., Luo, Y., Yin, J., & Ma, L. (2026). Leveraging large multimodal models for audio-video deepfake detection: a pilot study. *arXiv preprint arXiv:2602.23393*.
- [62] Reynolds D A. An overview of automatic speaker recognition technology [C]//Proceedings of the 2002 IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP). 2002: 4072-4075.
- [63] Li J, Chen C, Azghadi M R, Ghodosi H, Pan L, Zhang J. Security and Privacy Problems in Voice Assistant Applications: A Survey[J]. Computers & Security, 2023, 134: 103448.
- [64] Wu Z, Kinnunen T, Evans N, et al. ASVspoof: The Automatic Speaker Verification Spoofing and Countermeasures Challenge[J]. IEEE Journal of Selected Topics in Signal Processing, 2017, 11(4): 588-604.
- [65] Delgado H, Evans N, Kinnunen T, et al. ASVspoof 2021: Automatic Speaker Verification Spoofing and Countermeasures Challenge Evaluation Plan[EB/OL]. arXiv:2109.00535, 2021.
- [66] Yi J, Wang C, Tao J, Zhang X, Zhang C Y, Zhao Y. Audio Deepfake Detection: A Survey[J/OL]. arXiv:2308.14970, 2023.
- [67] Zhang B, Wu Z, Wang X, et al. Audio Deepfake Detection: What Has Been Achieved So Far and What Lies Ahead?[J]. 2025.
- [68] Capogrosso L, Cunico F, Cavicchioli R, et al. A Machine Learning-Oriented Survey on

参考文献

- TinyML[J/OL]. arXiv:2309.11932, 2023.
- [69] Ramadan M N A, et al. Federated Learning and TinyML on IoT Edge Devices: A Survey[J]. Internet of Things, 2025.
- [70] Okabe, Koji, Takafumi Koshinaka, and Koichi Shinoda. "Attentive statistics pooling for deep speaker embedding." *arXiv preprint arXiv:1803.10963* (2018).
- [71] Wang, Qiongqiong, Kong Aik Lee, and Tianchi Liu. "Scoring of large-margin embeddings for speaker verification: Cosine or PLDA?." *arXiv preprint arXiv:2204.03965* (2022).
- [72] Reynolds, Douglas A. "An overview of automatic speaker recognition technology." *2002 IEEE international conference on acoustics, speech, and signal processing* . Vol. 4. IEEE, 2002.
- [73] Young S, Evermann G, Gales M, et al. The HTK Book. 2006.
- [74] Huang, Guangpu, and Meng Joo Er. "Combined articulatory and auditory processing for improved speech recognition." *2012 7th IEEE Conference on Industrial Electronics and Applications (ICIEA)* . IEEE, 2012.
- [75] Yi, Jiangyan, et al. "Audio deepfake detection: A survey." *arXiv preprint arXiv:2308.14970* (2023).
- [76] Kamble, Madhu R., et al. "Advances in anti-spoofing: from the perspective of ASVspoof challenges." *APSIPA Transactions on Signal and Information Processing* 9 (2020): e2.
- [77] Khan, Awais, et al. "Voice spoofing countermeasures: Taxonomy, state-of-the-art, experimental analysis of generalizability, open challenges, and the way forward." *arXiv preprint arXiv:2210.00417* (2022).
- [78] Borrelli, Clara, et al. "Synthetic speech detection through short-term and long-term prediction traces." *EURASIP Journal on Information Security* 2021.1 (2021): 2.
- [79] Tahaoglu, Gul, et al. "Deepfake audio detection with spectral features and ResNeXt-based architecture." *Knowledge-Based Systems* 323 (2025): 113726.
- [80] Cheng, Zhe, et al. "Explainable AI for forensic speech authentication within cognitive and computational neuroscience." *Frontiers in Neuroscience* 19 (2025): 1692122.

攻读学位期间研究成果

- (1) ICASSP(International Conference on Acoustics, Speech, and Signal Processing)2025
一作 两篇
- (2) ICASSP(International Conference on Acoustics, Speech, and Signal Processing)2026
共一 一篇
- (3) 发明专利 第一发明人(目前已通过初审)